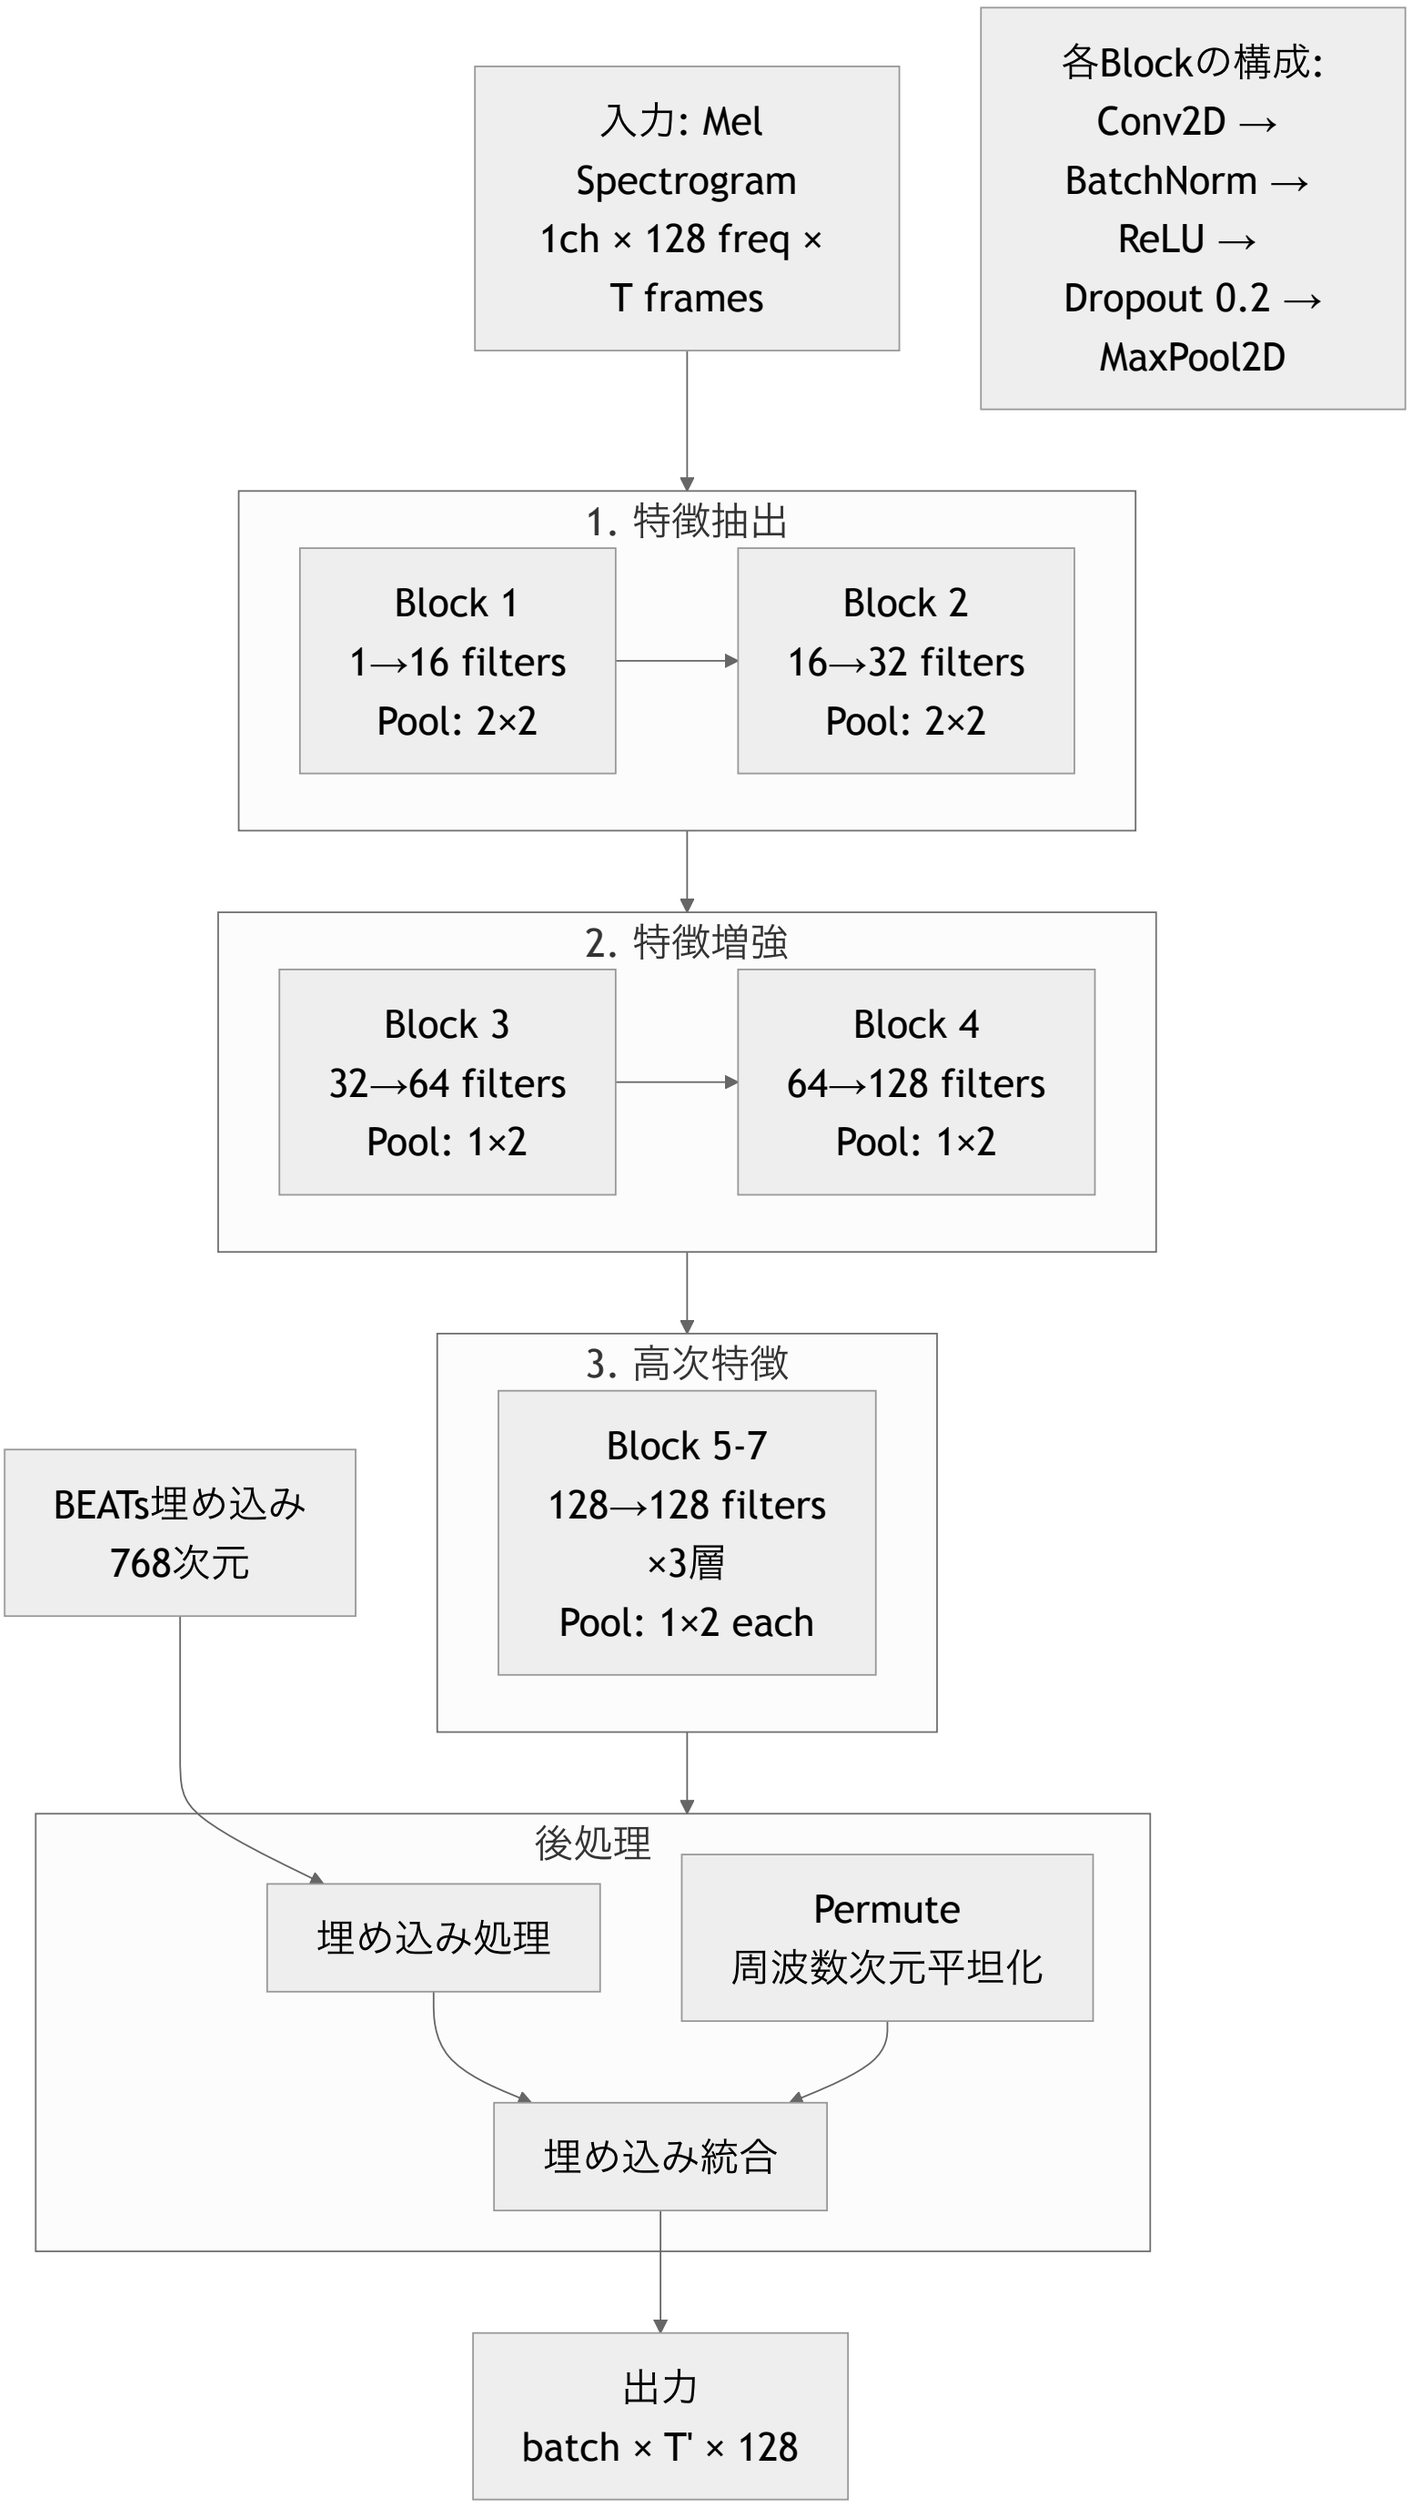

入力: Mel Spectrogram
1ch × 128 freq × T frames
各Blockの構成:
Conv2D →
BatchNorm →
ReLU →
Dropout 0.2 →
MaxPool2D
1. 特徴抽出
Block 1
1→16 filters
Pool: 2×2
Block 2
16→32 filters
Pool: 2×2
2. 特徴増強
Block 3
32→64 filters
Pool: 1×2
Block 4
64→128 filters
Pool: 1×2
3. 高次特徴
Block 5-7
128→128 filters
×3層
Pool: 1×2 each
BEATs埋め込み
768次元
後処理
埋め込み処理
Permute
周波数次元平坦化
埋め込み統合
出力
batch × T' × 128