一般社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
IEICE Technical Report

実環境を見据えた音による行動認識モデルの精度向上

竹本　志恩†　　川原　亮一†

† 東洋大学情報連携学部 〒115-8650 東京都北区赤羽台 1-7-11
E-mail: †{s1f102201278,ryoichi.kawahara}@iniad.org

あらまし　近年，少子高齢化よる介護人材の不足が懸念される．その解決策として，行動認識による自立的な生活の支援がある．この行動認識はセンサによって実現される．主要なセンサはカメラやウェアラブルだが，それらの欠点を補完するため，マイクによる行動認識を検討する．特にプライバシーに配慮した高齢者見守りに向け，音響イベント検出の実環境適用を目指す．具体的には，モデルパラメータを増大させずに精度を向上させるため，信頼度を用いた半教師あり学習とドメイン汎化手法のアーキテクチャを改良し，統合した．実験の結果，モデル規模を維持したまま先行実装を上回る精度を達成した．また，部分的に先行研究から精度を向上した．これらの結果から，提案手法の有効性を確認した．

キーワード　自立生活支援，行動認識，音響イベント検出

Improving Accuracy of Audio-Based Activity Recognition Models for Real-World Environments

Shion TAKEMOTO† and Ryoichi KAWAHARA†

† Faculty of Information Networking for Innovation and Design, Toyo University
1-7-11 Akabanedai, Kita-ku, Tokyo, 115-8650 Japan
E-mail: †{s1f102201278,ryoichi.kawahara}@iniad.org

Abstract　In recent years, there have been growing concerns regarding the shortage of nursing care personnel due to the declining birthrate and aging population. As a potential solution, supporting independent living through activity recognition has gained attention. While this is typically achieved using sensors—primarily cameras and wearables—we explore activity recognition via microphones to compensate for the inherent drawbacks of these existing technologies. Focusing on privacy-conscious elderly monitoring, we aim to apply Sound Event Detection (SED) to real-world environments. Specifically, to improve accuracy without increasing the number of model parameters, we refined and integrated architectures for semi-supervised learning using confidence scores and domain generalization. Experimental results demonstrate that our approach achieves higher accuracy than previous implementations while maintaining the model scale, and partially outperforms existing research. These results confirm the effectiveness of the proposed method.

Key words　Ambient Assisted Living, Human Activity Recognition, Sound Event Detection

1. はじめに

少子高齢化が急速に進行する日本において，介護資源の不足は深刻な社会問題であり，ICT を活用して高齢者の自立生活を支援する Ambient Assisted Living (AAL) の重要性が高まっている．

AAL の核心技術である行動認識において，従来主流であったウェアラブルセンサは，認知機能が低下した高齢者にとって装着忘れや充電管理の負担が大きく，常時監視による心理的・身体的ストレスも課題となる．また，カメラによる監視は情報量が豊富である反面，プライバシーへの抵抗感が強く，浴室や洗面所といった事故リスクの高い場所への設置が倫理的に困難であるほか，死角や暗所での認識精度低下も避けられない．

これに対し本稿では，プライバシー受容性が高く，死角の影響を受けにくいマイクロフォンを用いた音響イベント検出（Sound Event Detection; SED）に着目する．環境音を用いた SED は，流水音や転倒音といった特定の音響イベントを捉えることで，視覚情報を伴わずに危険な状況や生活文脈を把握できる可能性がある．しかし，実環境での運用には，生活雑音や部屋の残響特性といった環境要因による精度低下の克服が不可

This article is a technical report without peer review, and its polished and/or extended version may be published elsewhere.
Copyright ©20xx by IEICE

欠である．

また，近年の Detection and Classification of Acoustic Scenes and Events（DCASE）チャレンジ等における高精度モデルは大規模化する傾向にあるが，家庭内への実装を考慮すれば，計算リソースを抑えた軽量なモデルでの精度向上が求められる．

そこで本稿では，実環境での堅牢な行動認識を目指し，モデルパラメータを増大させずに SED の精度を向上させる手法を提案する．具体的には，信頼度を用いた半教師あり学習（Confident Mean Teacher; CMT）とドメイン汎化を目的とした MixStyle を改良し，統合した．

2. 関 連 研 究

2.1 行 動 認 識

日本における少子高齢化の進行に伴い，医療・介護資源の不足は喫緊の課題である．この解決策の一つとして，情報技術を活用して高齢者や障がい者の生活支援を行う AAL が挙げられる．AAL は在宅での自立生活を促進することで，医療や介護で発生する労働時間や社会保障費などの社会的コストを抑制すると同時に，被介護者の生活の質（Quality of Life; QoL）向上に寄与することを目指すものである [1].

AAL の要素技術である行動認識は，センサを用いて居住者の行動を認識し，異常行動の検知や健康状態の把握を行う．従来の研究では，主にウェアラブルセンサ，カメラ，あるいはその他の環境設置型センサが用いられてきた．

ウェアラブルセンサは，対象者の状態を常時取得でき，転倒などの異常を即時に検知できる．しかし，高齢者の認知機能低下に伴う装着忘れや充電等の管理不備のリスクが伴う．加えて，常時機器を身につけることによる身体的な不快感や拘束感のみならず，被監視による心理的圧迫感が課題となる [2].

一方，カメラは情報量が豊富で具体的な行動認識が容易な上，身体への装着も不要である．しかし，マイクロフォンと比較して導入コストが高くなりがちであり，プライバシーの観点から被介護者の心理的抵抗感が強い場合もある．また，撮影範囲の死角や，夜間の暗所において認識精度が低下する点も課題である [2], [3].

その他の非接触な手法として，家具や床に設置する圧力センサや，無線通信波の変動を利用して行動を検知する環境センサなどを利用する方法がある [2]．これらは身体的負担がない点で優れるが，本稿ではこれらに加え，聴覚情報が持つ「環境音」や「発話」などの多面的な情報に着目する．

マイクロフォンは設置が容易でありながら，死角の影響を受けにくく，かつカメラよりもプライバシー受容性が高い．特に，カメラの設置が倫理的に難しい浴室や洗面所においては，その有用性は高いと考えられる [4]．例えば，ヒートショックによる転倒や溺水が発生した際，流水音の継続や転倒時の衝撃音といった特定の音響イベントを捉えることで，視覚的なプライバシーを侵害することなく異常を検知できる可能性がある．

しかし，実環境におけるマイクロフォンの運用には課題も残る．換気扇の稼働音や生活雑音などの環境ノイズ，あるいは部屋の形状に起因する残響特性の違いが，認識精度を低下させる要因となるためである [5].

本稿はマイクロフォンを含む複数のセンサを統合し，多様な文脈を考慮した柔軟な行動認識システムの構築を目的に，その初期検討として，実環境特有のノイズや環境要因に対し，マイクロフォンによる行動認識精度を向上させる手法について検討する．

2.2 音響イベント検出

他方， 音響信号から事象の種類と発生時刻を特定する音響イベント検出（SED）の研究が活発化している．SED は， 音響イベントのクラス識別および時間区間検出を同時に行う技術であり， 本稿では音による行動認識の手段としてこれを位置付ける．本タスクでは 10 秒間の音声データを「クリップ」，それをさらに短時間で分割した単位を「フレーム」と定義し，それらを入力として受け取り，イベント種別及び各イベントの開始・終了時刻を予測する．

これらはラベルの定義とも関連する．利用するデータについて，時間的な詳細情報を含むものを「強ラベル」，イベントの有無のみを示すものを「弱ラベル」とし，それぞれフレームとクリップに対応する．

2.3 先 行 研 究

家庭内環境向け SED のコンペディションとして， DCASE チャレンジが知られている．DCASE 2024 Task 4 (DCASE 2024) は， 大規模な未ラベルデータを用いた複数の事前学習済みモデルの活用が精度向上に寄与し， 上位成績を収めた [6]．しかし， これらの手法はモデルの大規模化を招き， パラメータ数が著しく増大するという課題がある．実環境への実装を想定した場合， モデルのパラメータ増加は望ましくない．本稿では， モデルサイズを維持しつつ精度を向上させることを目的に，半教師あり学習とドメイン汎化手法を改良し，それらの統合を提案する．

提案では，DCASE 2024 の評価基準モデルを先行実装(注1)とする．先行実装は半教師あり学習手法として Mean Teacher (MT) を用いる．これは通常のモデルを「生徒」，生徒モデルの重みパラメータの指数移動平均を「教師」と定義し，入力にノイズが加わろうと教師と生徒の予測は同様という仮定の下，両予測の差を一貫性損失として扱う．この損失は平均二乗誤差で求められる．具体的には，教師がラベルなしデータに対して行う予測を擬似的な目標値とし，生徒予測との一貫性を高めることで，ラベルなしデータを活用する [7].

MT に対して CMT は，教師予測に閾値を設け，信頼できる予測のみ学習に用いることで精度向上を図る [8]．CMT は確率値が 0.5 より大きい予測のみ用いるが，閾値未満の確率値を持つ予測は損失に寄与せず，「イベントがない」ことの学習が難しい．当環境で検証したところ，CMT は MT に比べてイベントの分類予測精度を向上したが，イベントの開始や終了時刻の予測精度（時間的な精度）は低下した．なお，CMT 及びその検証を行った論文では両方の精度向上が報告されたが，い

(注1)：https://github.com/DCASE-REPO/DESED_task/tree/master/recipes/dcase2024_task4_baseline

ずれも実装が非公開で，検証が難しい [9].

提案では確率値 0.7 以上の予測を正例，0.3 以下の予測を負例とし，両方を学習する．CMT に比べ，あまり自信のない確率値 0.5 付近の予測を使わず，より安定した精度が得られると共に，フレーム単位での「イベントがない」ことを学習することで，時間的精度の向上が期待される．

次に，ドメイン汎化について述べる．ここでドメインとは，同一のクラスラベルであっても，データが観測された環境や条件によって生じる特徴分布の違いを指す．例えば，画像認識では実写とイラストが異なるドメインとして扱われる．同様に，録音環境や背景雑音の違いにより，種類の同じ音響イベントでも周波数などの特徴が異なる．モデルがこうした環境依存の情報に過剰適合することを防ぎ，未知の環境でもロバストな推論を可能にすることがドメイン汎化の目的である．

MixStyle [10] はドメイン汎化に有効なデータ拡張手法の一つである．先行研究 [11] において周波数領域の注意機構との統合が示唆されているが，その具体的なアーキテクチャは詳述されていない．そこで本稿では，より軽量な畳み込みニューラルネットワーク (Convolutional Neural Network; CNN) での統合を提案する．

3. 先行実装

3.1 データセット

評価用データセットとして Domestic Environment Sound Event Detection Dataset (DESED)，および MAESTRO Real の 21 クラスを使用する [12]〜[14].

これらデータセットのラベルには種類がある．弱ラベルはイベント種別のみを，強ラベルは開始・終了時刻も含み，それぞれクリップとフレームに対応する．

データセットに含まれる音声について，DESED は家庭内の音響イベント検出に向けて，実環境で録音した家庭内の生活音と，そのような環境を再現するために合成された音が含まれる．音声データは 10 秒間のモノラルオーディオで，サンプリングレート 16kHz または 44.1kHz となっている．MAESTRO Real は実環境の 3 – 5 分の音が含まれる．ラベルは 0 か 1 ではなく，0.8 などの連続値 (ソフトラベル) で，強ラベルが付与されている．

3.2 評価指標

本稿では DCASE2024 に基づき，データセットに応じて異なる評価指標を採用する．DESED では Polyphonic Sound Detection Score（PSDS）[15] のシナリオ 1 及び 2 を用い，MAESTRO Real では mpAUC（Macro-averaged Partial AUC．なお，AUC (Area Under the Curve) は ROC (Receiver Operating Characteristic) 曲線の下部）を主要な指標とする．

PSDS は，混同行列に基づく ROC 曲線を拡張した PSD-ROC 曲線を用いて算出される．通常の ROC 曲線は，縦軸に真陽性率（TPR），横軸に偽陽性率（FPR）をとるが，PSD-ROC 曲線では横軸に単位時間あたりの誤検知数（Effective False Positive Rate）を採用する点が異なる．

PSDS には目的に応じたシナリオが存在する．シナリオ 1（$PSDS_1$）は時間的な正確さを重視し，イベントの検知区間が正解と厳密に一致することを求める一方，クラス分類の誤りには比較的寛容である．対照的に，シナリオ 2（$PSDS_2$）はイベントのクラス分類性能を重視し，時間的なズレに対する許容範囲が広く設定されている．

本稿では，時間精度の向上とイベント分類の最適化を段階的に分離することを想定しており，現段階では正確なクラス分類を優先課題としている．したがって，$PSDS_2$ を最重要指標と位置付けるが，モデルの総合的な挙動を把握するため $PSDS_1$ も併せて評価する．

一方，MAESTRO Real の評価に用いる mpAUC は，ROC 曲線の全領域ではなく，誤検知率が低い領域（低 FPR 領域）に限定して曲線下面積（AUC）を算出する指標である．これは，実用上許容できない高い誤検知率の領域を評価から除外することで，モデルの信頼性をより厳密に評価するためである．

3.3 先行実装モデルの流れ

先行実装モデルの処理は学習と検証，評価の三段階に区分される．これ以降，先行実装モデルについて，基本的に DCASE 2024 の公式設定に準拠する．

データの前処理の後，学習を 150 エポック行う．モデルは入力に対し，ラベルごとの予測（弱/強 予測）を出力する．予測と正解ラベルを用いて教師あり及び半教師あり学習の損失を計算し，Adam [16] で生徒モデルを，指数移動平均で教師モデルを更新する．

検証は 10 エポックごとに行う．学習したモデルで検証用データを入力に推論し，精度を測る．過去の検証時より向上した場合，評価及び推論用に重みパラメータを保持する．評価は評価用データで検証と同様の作業が行われる．

3.4 モデル構成

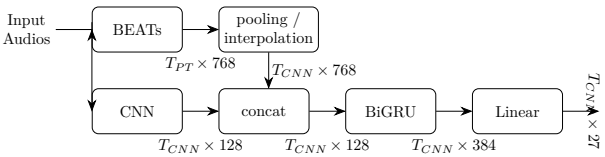


図 1　各段階の次元数は特徴量の時間長 (フレーム数) と周波数を表す．BEATs の出力を調整して CNN の出力と統合．RNN に入力し，最終的に予測を得る．なお，T: 時間長，PT: 事前学習モデルとする．

先行実装は図 1 のように，時間周波数領域の局所的な特徴を抽出する CNN と，時系列情報を学習しイベントの時間的変化をモデル化する再帰型ニューラルネットワーク（Recurrent Neural Network; RNN）を組み合わせた，CRNN（Convolutional Recurrent Neural Network）アーキテクチャである．特徴抽出器として事前学習された BEATs（Bidirectional Encoder representation from Audio Transformers）[17] を用いて，学習コストを抑制しながらタスクに有効な特徴表現を獲得する．

BEATs への入力は CNN と次元数が異なるが，出力は時間解

像度を補間することで CNN と統合される．

3.4.1 CNN

CNN は 7 つの畳み込みブロックで構成され，ブロックは Conv2D，Batch Normalization，ReLU，Dropout，及び MaxPool2D を順に積層する．BEATs の出力との統合のため特徴量の次元数（バッチ数，チャネル数，時間長 (フレーム数)，周波数）を調整し，RNN に出力する．

3.4.2 RNN

RNN には双方向 Gated Recurrent Unit（Bidirectional GRU; Bi-GRU）を使用し，順方向と逆方向に特徴を処理することで，イベントの時間的な変化を学習する．

3.5 出　　力

先行実装の出力段は RNN の出力（Batch × Time × 384）を強/弱予測に変換する．出力は全結合層と Sigmoid 活性化関数で 27 クラスに対する強予測に変換され，それらを Attention 機構による時間方向に集約して弱予測を得る．なお，評価に用いるのは 21 クラスである．

4. CMT

CMT は MT の教師予測に対し，クリップ及びフレーム単位で閾値を設ける．はじめに弱予測で判定し，閾値を下回った予測は同区間の強予測も含め学習しない．次に，閾値を上回る弱予測と同区間の強予測で同様に判定し，イベント種別に応じた窓サイズを持つ Median Filter で平滑化と外れ値の除去を行う．損失計算では二値化された信頼度マスクを重みとして教師予測に適用し，教師と生徒の予測間で二値交差エントロピー（Binary Cross Entropy; BCE）を最小化する．

この CMT は当環境ではイベント検知の評価指標である PSDS2 は向上したものの，時間的な境界の精度（時間分解能）を重視する PSDS1 が低下した．これは CMT が閾値以下の予測を損失計算から除外するため，確信度の低い予測，すなわち「イベントが存在しない」という情報が学習されないことに起因すると考えられ，その結果，時間分解能が低下したと解釈できる．

そこで本稿では，負例を明示的に学習に組み込み，PSDS2 の改善を維持しつつ PSDS1 を回復させる．具体的には，確率 0.7 以上の予測を「信頼できる正例」，確率 0.3 以下の予測を「信頼できる負例」とし，モデルの自信が曖昧な予測を除外する．これにより，ラベルなしデータにおける「イベントなし」情報を学習する．この時，正例と負例のサンプル数の偏りによって精度が低下する恐れがある．そこで，量の少ない方にサンプリングする均衡化処理も導入する．

5. MixStyle

MixStyle は，画像認識分野においてドメイン汎化のため提案されたデータ拡張手法である．画像における MixStyle は空間情報に着目する．チャネル方向で平均と分散 (統計量) を計算し，いずれかを足し合わせることで混合する．一方で，音響信号は時間と周波数の次元を持ち，ドメイン情報は主に周波数領域に局在することが示唆されている [18]．この特性を踏まえ，Xiao ら [11] は時間方向の統計量を計算し，周波数軸に沿って統計量を混合する手法を提案した．これにより，元のデータに含まれる意味的な情報を保持しつつ，新たなドメインスタイルを持つデータを生成し，モデルが特定ドメインに過剰適合することを防ぐ．

先行研究 [11] では MixStyle と周波数注意機構が結合されたが，具体的な統合プロセスや相互作用に関する詳細な記述が不足している．そこで本稿では，周波数領域におけるドメイン汎化性能をより軽量に高めるため，MixStyle と CNN を明示的に統合する．本手法は以下の 3 段階で構成され，重要な信号情報を損失することなく，効果的なドメイン適応を実現する．

（1） CNN による重要周波数帯域の特定
（2） 重要度を考慮した重み付き統計量の混合
（3） 残差接続による原信号のドメイン情報の保持

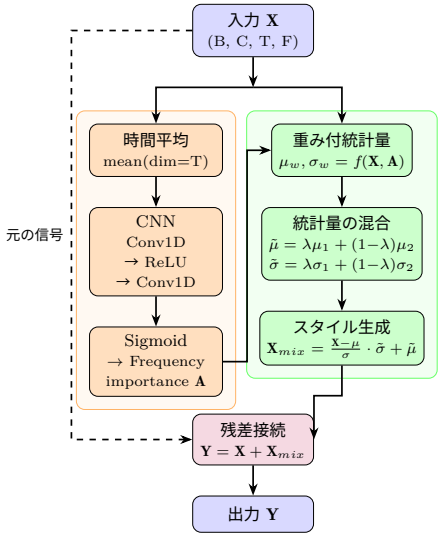


図 2　オレンジの領域が CNN，緑が MixStyle，そして赤が残差接続で，それぞれ本文の 1 から 3 に対応する．

MixStyle の適用箇所は [11] に準拠し，CNN への入力直前の特徴量，及び第 1・第 2 畳み込み層の直後の計 3 箇所とした．ハイパーパラメータは [10] を参考に，適用確率を $p = 0.5$，ベータ分布のパラメータを $\alpha = 0.1$ と設定した．混合するスタイルのソースとなるデータは，ミニバッチ内からランダムに選択される．本実験では汎化対象として DESED（合成音）と MAESTRO Real（実録音）を使用しているが，MixStyle はランダムなシャッフルであっても十分な正則化効果が得られることが報告されているため，計算コストと実装の複雑性を考慮し，バッチ内ランダム選択を採用した．

提案手法を具体的に説明する．入力特徴量を $X \in \mathbb{R}^{B\times C\times T\times F}$ とする（B, C, T, F はそれぞれバッチサイズ，チャネル数，時間，周波数の次元を表す）．まず，時間方向に対して平均を取り，時間情報を集約した周波数特徴記述子 $Z \in \mathbb{R}^{B\times C\times F}$ を得る．

$$Z_{b,c,f} = \frac{1}{T}\sum_{t=1}^{T} X_{b,c,t,f}$$

続いて，この特徴量に対して軽量な CNN を適用し，周波数

ごとの重要度マップ $A \in \mathbb{R}^{B\times C\times 1\times F}$ を生成する．具体的には，カーネルサイズ 3 の 1 次元畳み込み層，ReLU 活性化関数，及びカーネルサイズ 1 の畳み込み層からなるボトルネック構造を採用した．最終層には Sigmoid 関数を適用し，値域を $(0, 1)$ に正規化している．

$$A = \sigma(W_2 \cdot \delta(W_1 \cdot Z))$$

ここで δ は ReLU 関数，W_1, W_2 は畳み込み層の重みを表す．学習の初期段階における勾配消失を防ぎ，混合を促進するため，最終層のバイアスは 1.0 で初期化した．

推定された重要度 A を用いて，重み付き平均 μ 及び重み付き標準偏差 σ を算出する．これらを用いて正規化及び異種ドメイン（バッチ内の他データ）の統計量との混合を行い，新たな特徴量 X_{mix} を生成する．最後に，元の信号情報の損失を防ぐため，生成された特徴量を残差成分として元の入力に加算する．

$$Y = X + \text{MixStyle}(X, A)$$

この残差構造により，モデルは元の信号に含まれる重要なイベント情報を保持しつつ，MixStyle によるドメイン変動への頑健性を学習することが可能となる．

6. 実　　験

先行実装及び先行研究に対する精度向上及び各要素の有効性を示すため，本稿では 3 つの実験を行う．

まず，半教師あり学習の比較を行う．先行実装（MT），先行研究（CMT），及び提案手法を対象とし，それぞれの識別性能を評価する．

次に，アーキテクチャの検討を行う．MixStyle を既存モデルに直接適用する場合と，軽量 CNN を介して統合する場合とで，精度の変化を比較する．

最後に，構成要素の比較を行う．半教師あり学習の三手法に対し，MixStyle を併用して学習を行い，上記の結果と合わせて各モジュールの導入効果を検証する．

なお，実験環境は以下の通り：

- OS: Ubuntu 24.04.3 LTS (Noble Numbat)
- Kernel: 6.14.0-36-generic
- CPU: AMD Ryzen 7 5700X 8-Core Processor, x86_64
- GPU: NVIDIA GeForce RTX 4070, 12282 MiB
- RAM: 15GiB

7. 結果と考察

7.1 CMT

Model	PSDS1	PSDS2	mpAUC
Mean Teacher(MT)	0.369	0.581	0.720
Confident Mean Teacher(CMT)	0.297	0.60	0.689
CMT_{neg}	0.369	0.543	0.661
CMT_{scale}	0.368	0.621	0.699

表 1　Mean Teacher 比較

表 1 に各手法の精度比較を示す．MT と比較して，CMT は PSDS2 が向上した一方で，PSDS1 及び mpAUC は低下した．これに対し，単純に正例と負例を学習する CMT_{neg} は，CMT で見られた PSDS1 の低下は改善されたものの，その他の指標においては精度が悪化した．正例と負例の間に均衡化処理を施した CMT_{scale} は，MT と同等の PSDS1 を維持しつつ，PSDS2 においては CMT を上回る性能を示した．ただし，mpAUC は MT に及ばなかった．

CMT における PSDS1 の低下は，非イベント区間の情報（負例）の欠落で時間的な予測が不安定になったためと考えられる．CMT_{neg} では負例の導入によりこの問題を解決したが，正例に対する負例の割合が過多となり，逆にクラス分類（PSDS2 など）の予測が不安定化した．以上の結果から，CMT_{scale} における正例と負例の量の調整が，時間精度とクラス分類精度の双方を安定化させるために有効であったと結論づけられる．

7.2 クラス別 CMT

ここで CMT について，クラスごとの精度を評価する．表 2 に各クラスにおける $PSDS_2$ 及び mpAUC の結果を示す．

本稿の将来的な目標である異常検知において，異常発生の重要な文脈となる「流水（Running water）」と「足音（Footsteps）」のクラスに着目する．ベースラインの MT と比較して，提案手法である CMT_{scale} は，流水の $PSDS_2$ において 0.88 から 0.91 へ，足音の mpAUC において 0.68 から 0.71 へと，それぞれ精度の向上を達成した．

また，表 2 の他手法と比較して 5% 以上の精度変化があったクラスについて，向上は青，低下は赤で強調した．向上したクラスではある音が長く持続するが，低下したクラスでは瞬間的な音が続く．このことから，提案手法は長期的な音が捉えられる代わりに，瞬間的な音を取りこぼす傾向にあると考えられる．

PSDS（DESED）				mpAUC（MAESTRO）			
class	MT	CMT	CMT_s	class	MT	CMT	CMT_s
Alarm_bell	.868	.937	**.947**	Birds_singing	.971	.969	**.972**
Blender	.870	.885	**.920**	Brakes_squeak	.416	.398	**.463**
Cat	.881	**.929**	.911	Car	.825	**.866**	.817
Dishes	.501	**.641**	.602	Children voices	**.916**	.868	.881
Dog	.848	**.893**	.883	Cutlery/dishes	.595	.584	**.617**
Elec_shaver	.965	**.989**	.984	Footsteps	.681	.696	**.710**
Frying	.958	.948	**.970**	Large_vehicle	.653	.659	**.681**
Running_water	.887	.902	**.912**	Metro approach	**.833**	.807	.782
Speech	.775	.853	**.862**	Metro leaving	**.768**	.756	.740
Vacuum_clean	.901	.912	**.948**	People talking	**.665**	.662	.662
				Wind_blowing	.599	.324	**.744**

表 2　クラス別精度比較（CMT_s は CMT_{scale} の略）

7.3 MixStyle

CNN	PSDS1	PSDS2	mpAUC
-	0.375	0.581	0.709
✓	0.373	0.596	0.745

表 3　MixStyle+CNN の有無

MixStyle について，表 3 より，CNN による重み付けを行うと，PSDS2 と mpAUC が向上した．なお，半教師あり学習手法として Mean Teacher を使用している．これはドメイン汎化が上手く促されたことによるものか，データ拡張の適用による入力の変化で一貫性の制約が強くなったためと考えられる．ただし， 提案手法で述べたように，実際には重みづけが働いていない可能性がある．従来の MixStyle は混合した特徴量のみを用いるが，本稿では残差接続を行なっており，これが摂動として働き，精度が向上したことも考えられる．

7.4 CMT+MixStyle

MT-type	PSDS1	PSDS2	mpAUC
MT	0.382	0.607	0.704
CMT	0.387	0.637	0.722
CMT_{scale}	0.393	0.632	0.727

表 4　CMT と MixStyle を併用した結果

表 4 に，MT，CMT，CMT_{scale} を MixStyle と併用した場合の結果を示す．MT と CMT は PSDS1 及び PSDS2 が向上した一方で，mpAUC は低下した．CMT_{scale} は MT に比べて精度が向上したが，CMT との差は僅かだった．これは MixStyle の精度への影響が CMT より強いためだと考えられる．

表 1 と比較する．MixStyle の適用により，DESED（合成音・実録音）のみならず，性質の異なる MAESTRO（実録音）についても精度向上が期待されたが，mpAUC に関しては低下するケースも見られた．PSDS1，2 の向上については，MixStyle が特徴空間に摂動を与えることで，Teacher モデルと Student モデル間により一貫性を学習させた結果であると考えられる．特にこの一貫性がいずれの半教師あり学習でも効果を発揮し，CMT と CMT_{scale} の精度の差をごく僅かにしたと考えられる．

一連の結果より，提案手法である CMT と MixStyle の改良を統合した場合，MT と比較して全ての指標を向上させたが，CMT との差はごく僅かだった．正例に加え負例を活用する CMT_{scale} の有効性は示されたように思うが，あくまで MT の範疇であることに注意したい．また，MixStyle と軽量 CNN による重み付けも，精度向上に一定の寄与をすることが確認された．

8. むすび

本稿では，DCASE2024 Task 4 の評価基準モデルを基盤に，半教師あり学習手法 Confident Mean Teacher とドメイン汎化手法 MixStyle の改善の統合によって，音響イベント検出の精度向上を図った．結果として，負例を活用した CMT は，従来の MT や単純な CMT と比較して精度向上を達成した．また，周波数ごとの重要度に基づく MixStyle の統合が有効であることを再確認し，軽量な CNN を用いた場合でもドメイン汎化の効果が得られることを示した．

今後の課題として，CMT と MixStyle を併用した際に観測された，ベストモデル到達エポック数の減少（早期収束または不安定性）に関する詳細な解析や，他の半教師あり学習手法との性能比較，モデルの軽量化，時間推定タスクの上位レイヤ委譲などが挙げられる．

謝辞　共同研究費のことを記述

文　献

[1] S. Blackman, C. Matlo, C. Bobrovitskiy, A. Waldoch, M.L. Fang, P. Jackson, A. Mihailidis, L. Nygård, A. Astell, and A. Sixsmith, “Ambient assisted living technologies for aging well: a scoping review,” Journal of Intelligent Systems, vol.25, no.1, pp.55–69, 2016.

[2] B.M.V. Guerra, E. Torti, E. Marenzi, M. Schmid, S. Ramat, F. Leporati, and G. Danese, “Ambient assisted living for frail people through human activity recognition: state-of-the-art, challenges and future directions,” Frontiers in neuroscience, vol.17, p.1256682, 2023.

[3] D. Bouchabou, S.M. Nguyen, C. Lohr, B. LeDuc, and I. Kanellos, “A survey of human activity recognition in smart homes based on iot sensors algorithms: Taxonomies, challenges, and opportunities with deep learning,” Sensors, vol.21, no.18, p.6037, 2021.

[4] S.H. Hyun, “Sound-event detection of water-usage activities using transfer learning,” Sensors, vol.24, no.1, p.22, 2023.

[5] A. Mesaros, T. Heittola, T. Virtanen, and M.D. Plumbley, “Sound event detection: A tutorial,” IEEE Signal Processing Magazine, vol.38, no.5, pp.67–83, 2021.

[6] F. Schmid, P. Primus, T. Morocutti, J. Greif, and G. Widmer, “Improving audio spectrogram transformers for sound event detection through multi-stage training,” arXiv:2408.00791, 2024.

[7] A. Tarvainen and H. Valpola, “Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results,” Advances in Neural Information Processing Systems, vol.30, pp.1195–1204, 2017.

[8] S. Xiao, X. Zhang, and P. Zhang, “Multi-dimensional frequency dynamic convolution with confident mean teacher for sound event detection,” Proc. ICASSP, pp.1–5, 2023.

[9] Z. Niu, Q. Wu, and Y. Hu, “Sat-sed: Semi-supervised sound event detection by pseudo-labeling with self-adaptive threshold strategy,” 2025 IEEE 6th International Seminar on Artificial Intelligence, Networking and Information Technology (AINIT), pp.1743–1748, 2025.

[10] K. Zhou, Y. Yang, Y. Qiao, and T. Xiang, “Domain generalization with mixstyle,” Proc. ICLR, pp.1–15, 2021.

[11] Y. Xiao, H. Yin, J. Bai, and R.K. Das, “Fmsg-jless submission for dcase 2024 task4 on sound event detection with heterogeneous training dataset and potentially missing labels,” arXiv:2407.00291, 2024.

[12] N. Turpault, R. Serizel, A.P. Shah, and J. Salamon, “Sound event detection in domestic environments with weakly labeled data and soundscape synthesis,” Workshop on Detection and Classification of Acoustic Scenes and Events, pp.1–5, 2019.

[13] R. Serizel, N. Turpault, A. Shah, and J. Salamon, “Sound event detection in synthetic domestic environments,” Proc. ICASSP, pp.86–90, 2020.

[14] I. Martín-Morató and A. Mesaros, “Strong labeling of sound events using crowdsourced weak labels and annotator competence estimation,” IEEE/ACM transactions on audio, speech, and language processing, vol.31, pp.902–914, 2023.

[15] Ç. Bilen, G. Ferroni, F. Tuveri, J. Azcarreta, and S. Krstulović, “A framework for the robust evaluation of sound event detection,” Proc. ICASSP, pp.61–65, 2020.

[16] D.P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” Proc. ICLR, pp.1–15, 2015.

[17] S. Chen, Y. Wu, C. Wang, S. Liu, D. Tompkins, Z. Chen, and F. Wei, “Beats: Audio pre-training with acoustic tokenizers,” arXiv:2212.09058, 2022.

[18] B. Kim, S. Yang, J. Kim, H. Park, J. Lee, and S. Chang, “Domain generalization with relaxed instance frequency-wise normalization for multi-device acoustic scene classification,” arXiv:2206.12513, 2022.