一般社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
IEICE Technical Report

実環境を見据えた音による行動認識モデルの精度向上に関する一検討

竹本　志恩†　　川原　亮一†

† 東洋大学情報連携学部 〒115-8650 東京都北区赤羽台 1-7-11
E-mail: †{s1f102201278,ryoichi.kawahara}@iniad.org

あらまし　少子高齢化による介護人材不足の解決策として，行動認識による自立生活の支援がある．行動認識は主にカメラやウェアラブルといったセンサを用いるが，それらを補完し，かつプライバシーに配慮した高齢者見守りに向けて，マイクロフォンによる音響イベント検出の実環境適用を検討する．具体的には，モデルパラメータ数を増大させずに精度を向上させるため，信頼度を用いた半教師あり学習とドメイン汎化手法のアーキテクチャを改良・統合した．先行実装などとの比較評価実験を通じて，提案手法の有効性を分析した．

キーワード　自立生活支援，行動認識，音響イベント検出

A Study on Improving Accuracy of Audio-Based Activity Recognition Models for Real-World Environments

Shion TAKEMOTO† and Ryoichi KAWAHARA†

† Faculty of Information Networking for Innovation and Design, Toyo University
1-7-11 Akabanedai, Kita-ku, Tokyo, 115-8650 Japan
E-mail: †{s1f102201278,ryoichi.kawahara}@iniad.org

Abstract　In recent years, there have been growing concerns regarding the shortage of nursing care personnel due to the declining birthrate and aging population. As a potential solution, supporting independent living through activity recognition has gained attention. While this is typically achieved using sensors—primarily cameras and wearables—we explore activity recognition via microphones to compensate for these existing technologies. Focusing on privacy-conscious elderly monitoring, we aim to apply Sound Event Detection (SED) to real-world environments. Specifically, to improve accuracy without increasing the number of model parameters, we refined and integrated architectures for semi-supervised learning using confidence scores and domain generalization. In this paper, we analyze the effectiveness of the proposed approach through comparative experiments with prior implementations.

Key words　Ambient Assisted Living, Human Activity Recognition, Sound Event Detection

1. はじめに

少子高齢化が急速に進行する日本において，介護資源の不足は深刻な社会問題であり，情報通信技術を活用して高齢者の自立生活を支援する Ambient Assisted Living (AAL) の重要性が増している．

AAL の核となる行動認識において，主流の一つであるウェアラブルセンサは，認知機能が低下した高齢者にとって装着忘れや充電管理の負担が大きく，常時監視による心身のストレスを招く懸念がある．また，カメラによる監視は情報量が豊富である反面，プライバシーへの抵抗感が強く，浴室や洗面所といった事故リスクの高い場所への設置が困難であるほか，死角や照度の影響を受けやすい．

これに対し本研究では，プライバシー受容性が高く，死角の影響を受けにくいマイクロフォン (マイク) を用いた音響イベント検出（Sound Event Detection; SED）に着目する．環境音を用いた SED は，流水音や転倒音といった特定の音響イベントを捉えることで，視覚情報を伴わずに危険な状況や生活文脈を把握できると期待される．一方で，実環境での運用には，生活雑音や部屋の残響特性といった環境要因による精度低下の克服が不可欠である．

また，近年の Detection and Classification of Acoustic Scenes and Events（DCASE）チャレンジ [1] 等における高精度モデルは大規模化する傾向にあるが，エッジ実装を想定した家庭内利用では，計算資源を抑えた軽量モデルでの精度向上が求められる．

そこで本研究では，実環境での堅牢な行動認識を目指し，

This article is a technical report without peer review, and its polished and/or extended version may be published elsewhere.
Copyright ©20xx by IEICE

モデルパラメータを増大させずに SED の精度を向上させる手法を検討する．具体的には，信頼度を用いた半教師あり学習（Confident Mean Teacher; CMT）とドメイン汎化を目的とした MixStyle を改良・統合した．

2. 関 連 研 究

2.1 行 動 認 識

日本における少子高齢化の進展に伴い，医療・介護資源の不足は喫緊の課題である．この解決策の一つとして，情報通信技術を活用して高齢者や障がい者の生活支援を行う AAL が挙げられる．AAL は在宅での自立生活を促進することで，医療や介護で発生する労働時間や社会保障費などの社会的コストを抑制し，同時に被介護者の生活の質（Quality of Life; QoL）向上に寄与することを目指すものである [2].

AAL の基盤技術である行動認識は，センサを用いて居住者の行動を認識し，異常行動の検知や健康状態の把握を行う．従来の研究では，主にウェアラブルセンサ，カメラ，あるいは環境設置型センサが用いられてきた．

ウェアラブルセンサは，対象者の状態を常時取得でき，転倒などの異常を即時に検知できる．しかし，認知機能が低下した高齢者においては，装着忘れや充電管理の不備といった運用上のリスクが伴う．加えて，常時装着による身体的な負担や拘束感のみならず，被監視による心理的圧迫感が懸念される [3].

一方，カメラは豊富な視覚情報に基づき詳細な行動認識が可能であり，身体への装着も不要である．しかし，マイクと比較して導入コストが高くなりがちであり，プライバシーの観点から被介護者の心理的抵抗感が強い場合もある．また，撮影範囲の死角や暗所における認識精度の低下も課題である [3], [4].

その他の非接触的手法として，家具や床に設置する圧力センサや，無線通信波の変動を解析する環境センサなどの利用が挙げられる [3]．これらは身体的拘束を伴わない点で優位性を持つ．本研究ではこれらの利点を踏まえつつ，聴覚情報が内包する「環境音」や「発話」といった多面的な情報に着目する．

マイクは設置が容易でありながら，死角の影響を受けにくく，かつカメラよりもプライバシー受容性が高い．特に，カメラの設置が倫理的に困難な浴室や洗面所において，その有用性は高いと考えられる [5]．例えば，ヒートショックによる転倒や溺水が発生した際，流水音の継続や転倒時の衝撃音といった特定の音響イベントを捉えることで，視覚的なプライバシーを保護しつつ，異常を検知できる可能性がある．

しかし，実環境におけるマイクの運用には課題が残る．換気扇の稼働音や生活雑音などの環境ノイズ，及び室内形状に起因する残響特性の違いが，認識精度を低下させる要因となるためである [6].

本研究はマイクを含む複数のセンサを統合し，多様な文脈を考慮した柔軟な行動認識システムの構築を最終的な目的とする．その初期検討として，実環境におけるノイズなどの環境要因に対し，マイクによる行動認識精度を向上させる手法を検討する．

2.2 音響イベント検出

他方， 音響信号から事象の種類と発生時刻を特定する音響イベント検出（SED）の研究が活発化している．SED はクラス識別と時間区間検出を同時に行う技術であり， 本研究では音響による行動認識の手法としてこれを位置付ける．

本タスクでは 10 秒間の音響データを「クリップ」，その最小単位を「フレーム」と定義する．ラベル形式には，イベントの有無のみを示す「弱ラベル」と，開始・終了時刻を含む「強ラベル」の 2 種類が存在する．モデルはこれらを入力として受け取り，イベント種別及び時間区間の推定を行う．なお，本稿ではラベルの定義に準じ，それぞれの予測結果を「弱予測」，「強予測」と呼称する．

2.3 先 行 研 究

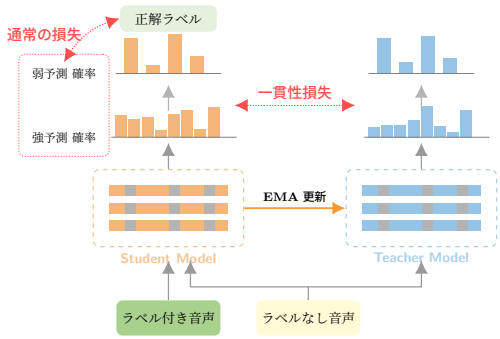


図 1　MT の更新の概略．DESED に対して適用する．Model 内の灰色部は DropOut による摂動を表す．

家庭内環境における SED のコンペディションとして DCASE チャレンジが挙げられる．DCASE 2024 Task 4 (DCASE 2024) においては，大規模な未ラベルデータを用いた複数の事前学習済みモデルの統合が精度向上に寄与し，上位成績を収めた [7].

しかし， こうした手法はモデルの大規模化を招く懸念がある．実環境への実装を考慮すると， パラメータ数の増加は計算資源の制約から望ましくない．本研究では， モデルサイズを維持しつつ精度を向上させるため，半教師あり学習とドメイン汎化手法を改良・統合する．

提案では，DCASE 2024 の評価基準モデルを先行実装(注1)として採用し，基本設定はこれに準拠する [1]．先行実装は半教師あり学習手法として Mean Teacher (MT) を用いる．図 1 に MT の概略を示す．MT は，通常のモデルである「生徒」，その重みパラメータの移動指数平均 (Exponential Moving Average; EMA) から算出される「教師」で構成される．入力に対する摂動 (ノイズ) に関わらず両者の予測は一致すべきであるという仮定に基づき，予測値間の平均二乗誤差を一貫性損失として扱う．これにより，教師予測を擬似ラベルとして生徒に学習させることで，未ラベルデータの活用を可能にする [8].

これに対し，予測値に閾値を設けて信頼性の高いサンプルのみを選択的に学習する CMT が提案されている [9]．しかし，

(注1)：https://github.com/DCASE-REPO/DESED_task/tree/master/recipes/dcase2024_task4_baseline

CMT は確率値が 0.5 を超える予測のみ用いるため，閾値未満の予測が損失計算に寄与せず，「イベントの不在」に関する学習が難しい．当環境での予備実験では，CMT は MT と比較してイベントの分類予測精度を向上したが，イベントの境界 (開始・終了時刻) の推定精度は低下した．なお，CMT 及びその検証を行った論文ではイベント分類及び時間境界の精度向上が報告されていた [10].

本研究では，予測確率 0.7 以上を正例，0.3 以下を負例とし，その双方を学習に用いる手法を提案する．不確実な 0.5 付近の予測を排して学習を安定化させるとともに，フレーム単位での負例 (イベントの不在) を学習することで，時間的精度の向上を図る．

次に，ドメイン汎化について述べる．ここでドメインとは，同一のクラスラベルであっても，観測環境やその条件によって生じる特徴分布の差異を指す．例えば，画像認識では実写とイラストが異なるドメインとして扱われる．音響信号においても同様に，録音環境や背景雑音の性質により，同一の音響イベントであっても周波数などの特徴が異なる．モデルがこうした環境依存情報に過剰適合することを防ぎ，未知の環境においてもロバストな推論を可能にすることがドメイン汎化の目的である．

MixStyle [11] はドメイン汎化に有効なデータ拡張手法の一つである．先行研究 [12] において周波数領域の注意機構との統合が示唆されているが，その具体的なアーキテクチャは詳述されていない．そこで本研究では，より軽量な畳み込みニューラルネットワーク (Convolutional Neural Network; CNN) での統合を提案する．

3. 先 行 実 装

3.1 データセット

評価用データセットとして Domestic Environment Sound Event Detection Dataset (DESED)(注2) [13], [14] の 10 クラスと，及び MAESTRO Real(注3) [15] の 11 クラス，計 21 クラスを使用する．クラス一覧は 6. 1. 1 節の表 3 に示す．また 2. 2 節で述べたように，データのラベルには種類がある．なお，ラベルのないデータもある．

データセットに含まれる音声について，DESED は家庭内の音響イベント検出に向けて，実環境で録音した家庭内の生活音と，環境の再現を目的とする合成音が含まれる．音声は 10 秒間のモノラルオーディオで，サンプリングレート 16kHz または 44.1kHz となっている．MAESTRO Real は実環境の 3 – 5 分の音が含まれる．ラベルは 0 か 1 ではなく，0.8 などの連続値 (ソフトラベル) で，強ラベルが付与されている．

DESED のデータは学習段階と作成法，ラベルで分類される．段階には訓練，検証，評価がある．なお，本研究では一部データが取得できていない．使用したデータ数を表 1 に示す．

利用段階	データ種別	数 [clips]
訓練	強ラベル，実録音	1613
訓練	弱ラベル，実録音	1188
訓練	強ラベル，合成音	10000
訓練	ラベルなし，実録音	12027
検証	弱ラベル，実録音	129
検証	強ラベル，合成音	2500
評価	強ラベル，実録音	958

表 1　DESED のデータ数

MAESTRO Real は 6426 クリップが含まれており，訓練データを訓練と検証で 9:1 に分割し，評価には評価データを用いた．

3.2 評 価 指 標

本研究は DCASE2024 に基づき，DESED では Polyphonic Sound Detection Score（PSDS）[16] のシナリオ 1 及び 2 を用い，MAESTRO Real では mpAUC（Macro-averaged Partial AUC. なお，AUC (Area Under the Curve) は ROC (Receiver Operating Characteristic) 曲線下部の面積）を用いる．

PSDS は，混同行列に基づく ROC 曲線を拡張した PSD-ROC 曲線を用いて算出される．通常の ROC 曲線は，縦軸に真陽性率（TPR），横軸に偽陽性率（FPR）をとるが，PSD-ROC 曲線では横軸に単位時間あたりの誤検知数（Effective False Positive Rate）を採用する点が異なる．

PSDS には目的に応じたシナリオが存在する．シナリオ 1（PSDS1）は時間的な正確さを重視し，イベントの検知区間が正解と厳密に一致することを求める一方，クラス分類の誤りには比較的寛容である．対照的に，シナリオ 2（PSDS2）はイベントのクラス分類性能を重視し，時間的なズレに対する許容範囲が広く設定されている．なお，詳細な定義は [16] を参照のこと．

本研究では，時間精度の向上とイベント分類の最適化を段階的に分離することを想定しており，現段階では PSDS2 を重視するが，モデルの総合的な評価のために PSDS1 も確認する．

一方，MAESTRO Real の評価に用いる mpAUC は，ROC 曲線の全領域ではなく，誤検知率が低い領域（低 FPR 領域）に限定して AUC を算出する指標である．これは，実用上許容できない高い誤検知率の領域を評価から除外することで，モデルの信頼性をより厳密に評価するためである．

3.3 先行実装モデルの流れ

モデルの流れは学習と検証，評価に区分される．データの前処理の後，学習を 150 エポック行う．モデルは入力に対し，強及び弱予測を出力する．予測とラベルによって損失を計算し，Adam [17] で生徒を，移動指数平均で教師を更新する．

検証は 10 エポックごとに行う．学習したモデルで検証用データを入力に推論し，精度を測る．過去の検証より精度が向上した場合，重みパラメータを保持する．学習後は評価用データで推論させ，各指標を確認する．

（注2）：https://github.com/turpaultn/DESED

（注3）：https://researchportal.tuni.fi/en/datasets/maestro-real-multi-annotator-estimated-strong-labels/

3.4 モデル構成

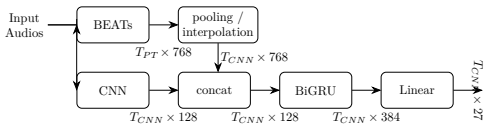


図 2　BEATs の出力を調整して CNN の出力と統合して RNN に入力し，最終的に予測を得る．T はフレーム数，PT は事前学習済みモデル．

先行実装は図 2 のように，時間周波数領域の局所的な特徴を抽出する CNN と，時系列情報を学習しイベントの時間的変化をモデル化する再帰型ニューラルネットワーク（Recurrent Neural Network; RNN）を組み合わせた，CRNN（Convolutional Recurrent Neural Network）アーキテクチャである．特徴抽出器として事前学習された BEATs（Bidirectional Encoder representation from Audio Transformers）[18] を用いて，学習コストを抑制しながらタスクに有効な特徴表現を獲得する．BEATs への入力は CNN と次元数が異なるが，出力は時間解像度を補間することで CNN と統合される．

なお，特徴量は対数メルスペクトログラムを用い，その次元はバッチサイズ B，チャネル数 C，時間 (フレーム数) T，周波数 F である．また，前処理では汎化性能向上のため，二つのデータを一定の比率で混合する Mixup を行う [19]．

3.4.1 CNN

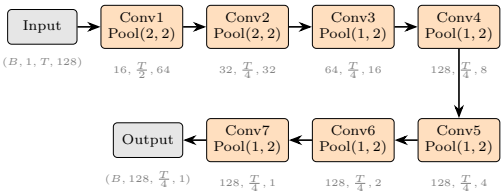


図 3　CNN の概略．各ブロック下は特徴量の次元数．

CNN は図 3 のように，7 つの畳み込みブロックで構成される．各ブロックでは Conv2D，Batch Normalization，ReLU，Dropout，及び MaxPool2D を順に積層する．

3.4.2 RNN

RNN には双方向 Gated Recurrent Unit（Bidirectional GRU; BiGRU）を使用し，順方向と逆方向に特徴を処理することで，イベントの時間的な変化を学習する．

3.5 出　　力

先行実装の出力段は RNN の出力（Batch × Time × 384，384 は周波数の次元数）を強/弱予測に変換する．出力は全結合層と Sigmoid 関数で強予測に変換され，それらを Attention 機構で時間方向に集約することで弱予測を得る．

4. 提 案 手 法

4.1 CMT [9]

CMT は MT の教師予測に対し，クリップ及びフレーム単位で閾値を適用する．まず，弱予測の結果に基づき，閾値未満の予測を同区間の強予測を含め学習対象から除外する．次に，閾値を上回る予測に対しては，イベント種別に応じた窓幅のメディアンフィルタを適用し，平滑化と外れ値の除去を行う．損失計算においては，二値化された信頼度マスクを重みとして，教師・生徒モデル間の二値交差エントロピー（Binary Cross Entropy; BCE）誤差を最小化する．

本実験環境において，CMT は PSDS2 を向上させた一方，PSDS1 を低下させた．これは，低確信度の予測を損失計算から一律に除外することで，「イベントが存在しない」という負例の情報が学習されず，結果として時間境界の推定精度が損なわれたためと考えられる．

そこで本研究では，負例を学習に組み込み，PSDS2 の改善を維持しつつ，PSDS1 の向上を図る．具体的には，確率 0.7 以上を「信頼できる正例」，0.3 以下を「信頼できる負例」とし，不確実な中間領域の予測のみを学習から除外する．さらに，正負例のサンプル不均衡による精度低下を回避するため，サンプル数の比率に基づく損失の正規化を行う．

4.2 MixStyle [11]

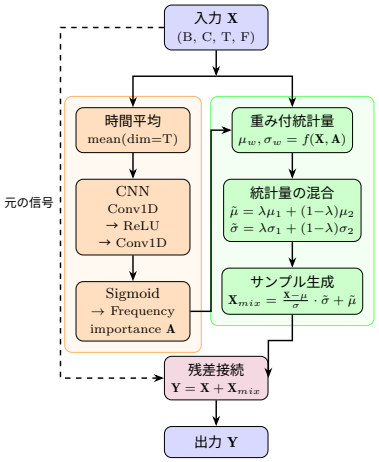


図 4　オレンジの領域が CNN，緑が MixStyle，そして赤が残差接続で，それぞれ本文の 1 から 3 に対応する．

MixStyle は，画像認識におけるドメイン汎化のために提案されたデータ拡張手法である．画像分野では空間情報に着目し，チャネルごとの平均と標準偏差をドメイン固有のスタイル統計量として抽出し，他データと混合する．一方で，音響信号は時間と周波数の次元を持ち，ドメイン情報は主に周波数領域に局在することが示唆されている [20]．この特性に基づき，Xiao ら [12] は時間方向の統計量を計算し，周波数軸に沿って混合する手法を提案した．これにより，元データに含まれる意味的な情報を保持しつつ，多様なドメインスタイルを生成し，特定ドメインへの過剰な適合を防ぐ．

しかし先行研究 [12] では，MixStyle と周波数方向の注意機構が結合されているものの，その統合プロセスや相互作用は詳らかにされていない．本研究では，周波数領域におけるドメイン汎化をより軽量に実現するため，MixStyle と CNN を統

合する．本手法は以下の 3 段階で構成され，重要な信号情報を損なうことなく効果的なドメイン適応を実現する．

（1） CNN による重要周波数帯域の特定

（2） 重要度を考慮した重み付き統計量の混合

（3） 残差接続による原信号のドメイン情報の保持

具体的なアーキテクチャを図 4 に示す．MixStyle の適用は [12] に倣い，CNN への入力直前，及び第 1・第 2 畳み込み層直後の特徴量を対象とした．ハイパーパラメータは [11] を参照し，適用確率を $p = 0.5$，ベータ分布のパラメータを $\alpha = 0.1$ に設定した．混合対象であるスタイル統計量は，ミニバッチ内からランダムに選択される．本実験では，ドメイン汎化の対象として合成音（DESED）と実録音（MAESTRO Real）を扱うが，MixStyle はランダムな選択であっても十分な正則化効果が得られることが報告されている [11]．したがって，計算コストと実装の簡便性を優先し，異なるスタイルを持つデータを選択するのではなく，バッチ内ランダム選択による混合を行った．

提案手法の詳細を以下に述べる．入力特徴量を $X \in \mathbb{R}^{B\times C\times T\times F}$ とする．まず，時間方向の平均を算出することで時間情報を集約し，周波数特徴記述子 $Z \in \mathbb{R}^{B\times C\times F}$ を得る．

$$Z_{b,c,f} = \frac{1}{T}\sum_{t=1}^{T} X_{b,c,t,f}$$

次に，Z に対して CNN を適用し，周波数ごとの重要度マップ $A \in \mathbb{R}^{B\times C\times 1\times F}$ を生成する．ネットワーク構成には，カーネルサイズ 3 の 1 次元畳み込み層，ReLU 関数 δ，及びカーネルサイズ 1 の 1 次元畳み込み層からなるボトルネック構造を採用した．最終層には Sigmoid 関数 σ を適用し，出力を $(0, 1)$ の範囲に正規化する．

$$A = \sigma(W_2 \cdot \delta(W_1 \cdot Z))$$

ここで，W_1, W_2 は畳み込み層の重みを表す．なお，学習初期の勾配消失を抑制し，統計量の混合を促進するため，最終層のバイアスは 1.0 で初期化した．

推定された重要度 A に基づき，周波数ごとの重み付き平均 μ 及び重み付き標準偏差 σ を算出する．これらを用いて正規化及び異種ドメイン（ミニバッチ内の他サンプル）との混合を行い，新たな特徴量 X_{mix} を生成する．最後に，元の信号情報の損失を防ぎつつドメイン不変性を獲得するため，下式に示す残差構造を導入する．

$$Y = X + \mathrm{MixStyle}(X, A)$$

5. 実　　験

先行実装及び先行研究に対する精度向上及び各要素の有効性を示すため，本研究では 3 つの実験を行う．

(i) まず，先行実装（MT），先行研究（CMT），及び提案手法を対象とし，それぞれの識別性能を評価する．(ii) 次に，MixStyle を既存モデルに直接適用する場合と，軽量 CNN を介して統合する場合とで，精度を比較する．(iii) 最後に，構成要素の比較を行う．半教師あり学習の三手法に対し，MixStyle を併用して学習を行い，上記の結果と合わせて各モジュールの導入効果を検証する．なお，実験環境は以下の通り：

- OS: Ubuntu 24.04.3 LTS (Noble Numbat)
- Kernel: 6.14.0-36-generic
- CPU: AMD Ryzen 7 5700X 8-Core Processor, x86_64
- GPU: NVIDIA GeForce RTX 4070, 12282 MiB
- RAM: 15GiB

6. 結果と考察

6.1 CMT

MT-type	PSDS1	PSDS2	mpAUC
Mean Teacher(MT)	0.369	0.581	0.720
Confident Mean Teacher(CMT)	0.297	0.60	0.689
CMT_{neg}	0.369	0.543	0.661
CMT_{scale}	0.368	0.621	0.699

表 2　Mean Teacher 比較

表 2 に各手法の精度比較を示す．MT と比較して，CMT は PSDS2 が向上したが，PSDS1 及び mpAUC は低下した．本研究の提案手法について見ると，正負例を学習する CMT_{neg} は，CMT における PSDS1 の低下を改善したが，他の精度は悪化した．正負例を均衡化する CMT_{scale} は，MT と同等の PSDS1 を維持しつつ，CMT を上回る PSDS2 を示した．ただし，mpAUC は MT に及ばなかった．

CMT における PSDS1 の低下は，非イベント区間の情報（負例）の欠落で時間的な予測が不安定になったためと考えられる．CMT_{neg} では負例の導入によりこの問題を解決したが，正例に対する負例の割合が過多となり，逆にクラス分類（PSDS2 及び mpAUC）の予測が不安定化した．よって，負例の使用と正負例の量の調整が，PSDS1，2 の安定に有効である．

6.1.1 クラス別 CMT

CMT におけるクラスごとの精度を表 3 に示す．

PSD2（DESED）				mpAUC（MAESTRO）			
class	MT	CMT	CMT_s	class	MT	CMT	CMT_s
Alarm_bell	.868	.937	**.947**	Birds_singing	.971	.969	**.972**
Blender	.870	.885	**.920**	Brakes_squeak	.416	.398	**.463**
Cat	.881	**.929**	.911	**Car**	.825	**.866**	.817
Dishes	.501	**.641**	.602	Children voices	**.916**	.868	.881
Dog	.848	**.893**	.883	Cutlery/dishes	.595	.584	**.617**
Elec_shaver	.965	**.989**	.984	**Footsteps**	.681	.696	**.710**
Frying	.958	.948	**.970**	Large_vehicle	.653	.659	**.681**
Running_water	.887	.902	**.912**	**Metro approach**	**.833**	.807	.782
Speech	.775	.853	**.862**	Metro leaving	**.768**	.756	.740
Vacuum_clean	.901	.912	**.948**	People talking	**.665**	.662	.662
				Wind_blowing	.599	.324	**.744**

表 3　クラス別精度比較（CMT_s は CMT_{scale} の略）

本研究の見据える異常検知において，浴室や洗面所で手掛かりとなる流水（Running water）と，日常的な活動や夜間の状態を捉えるのに用いることが想定される足音（Footsteps）に着目する．MT と比較して，提案手法である CMT_{scale} は，流水の PSDS2 において 0.89 から 0.91 へ，足音の mpAUC において 0.68 から 0.71 へと，それぞれ精度を向上達成した．

また，表 3 では，提案手法と MT 及び CMT を比較して 5%

以上の変化があるクラスについて，向上は青，低下は赤で強調した．向上クラスは音が長く持続するが，低下クラスでは瞬間的な音が続く．このことから，提案手法は長期的な音が捉えられる代わりに，瞬間的な音を取りこぼすと考えられる．

6.2 MixStyle

CNN	PSDS1	PSDS2	mpAUC
-	0.375	0.581	0.709
✓	0.373	0.596	0.745

表 4　MixStyle+CNN

表 4 より，CNN での重み付けによって PSDS2 と mpAUC が向上した．なお，半教師あり学習手法として MT を用いた．これはドメイン汎化がより促されたか，モデルの入力が変化し，一貫性の制約が強まったためと考えられる．ただ，重みづけは実際には働いていない可能性がある．また，従来の MixStyle は混合した特徴量のみを用いるが，提案は残差接続を行う．これが摂動として働き，一貫性の制約を強めた可能性もある．

6.3 CMT+MixStyle

MT-type	MixStyle	PSDS1	PSDS2	mpAUC
先行実装 (MT)	-	0.369	0.581	0.720
先行実装	✓	0.382	0.607	0.704
先行研究 (CMT)	-	0.297	0.60	0.689
先行研究	✓	0.387	0.637	0.722
提案手法 (CMT_{scale})	-	0.368	0.621	0.699
提案手法	✓	0.393	0.632	0.727

表 5　CMT+MixStyle

表 5 に，各種 MT を MixStyle と併用した場合の結果を示す．MT と CMT は PSDS1，2 が向上した一方で，mpAUC は低下した．CMT_{scale} は MT に比べて精度が向上したが，CMT との差は僅かである．これは MixStyle の精度への影響が CMT より強いためだと考えられる．

MixStyle の適用については，DESED（合成音・実録音）のみならず，性質の異なる MAESTRO（実録音）を含む精度向上が期待されたが，MT では mpAUC が低下した．特に PSDS1，2 の向上は，MixStyle が特徴空間に摂動を与え，教師及び生徒モデル間の一貫性を強めたためと考えられる．

7. むすび

本研究では，DCASE2024 Task 4 の評価基準モデルを基盤に，半教師あり学習とドメイン汎化手法の改善と統合によって，音響イベント検出の精度向上を図った．結果として，負例を活用した CMT は，従来の MT や単純な CMT と比較して PSDS1，PSDS2 を向上させた．また，周波数ごとの重要度に基づく MixStyle の有効性を再確認し，軽量な CNN でもドメイン汎化の効果が得られることを示した．

今後の課題として，CMT と MixStyle を併用した際に観測された，ベストモデル到達エポック数の減少（早期収束または不安定性）に関する詳細な解析や，他の半教師あり学習手法との性能比較，モデルの軽量化，時間推定の分離が挙げられる．

文　献

[1] S. Cornell, J. Ebbers, C. Douwes, I. Martín-Morató, M. Harju, A. Mesaros, and R. Serizel, “DCASE 2024 task 4: Sound event detection with heterogeneous data and missing labels,” arXiv:2406.08056, 2024.

[2] S. Blackman, C. Matlo, C. Bobrovitskiy, A. Waldoch, M.L. Fang, P. Jackson, A. Mihailidis, L. Nygård, A. Astell, and A. Sixsmith, “Ambient assisted living technologies for aging well: a scoping review,” Journal of Intelligent Systems, vol.25, no.1, pp.55–69, 2016.

[3] B.M.V. Guerra, E. Torti, E. Marenzi, M. Schmid, S. Ramat, F. Leporati, and G. Danese, “Ambient assisted living for frail people through human activity recognition: state-of-the-art, challenges and future directions,” Frontiers in neuroscience, vol.17, p.1256682, 2023.

[4] D. Bouchabou, S.M. Nguyen, C. Lohr, B. LeDuc, and I. Kanellos, “A survey of human activity recognition in smart homes based on IoT sensors algorithms: Taxonomies, challenges, and opportunities with deep learning,” Sensors, vol.21, no.18, p.6037, 2021.

[5] S.H. Hyun, “Sound-event detection of water-usage activities using transfer learning,” Sensors, vol.24, no.1, p.22, 2023.

[6] A. Mesaros, T. Heittola, T. Virtanen, and M.D. Plumbley, “Sound event detection: A tutorial,” IEEE Signal Processing Magazine, vol.38, no.5, pp.67–83, 2021.

[7] F. Schmid, P. Primus, T. Morocutti, J. Greif, and G. Widmer, “Improving audio spectrogram transformers for sound event detection through multi-stage training,” arXiv:2408.00791, 2024.

[8] A. Tarvainen and H. Valpola, “Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results,” Advances in Neural Information Processing Systems, vol.30, pp.1195–1204, 2017.

[9] S. Xiao, X. Zhang, and P. Zhang, “Multi-dimensional frequency dynamic convolution with confident mean teacher for sound event detection,” Proc. ICASSP, pp.1–5, 2023.

[10] Z. Niu, Q. Wu, and Y. Hu, “SAT-SED: Semi-Supervised Sound Event Detection by Pseudo-Labeling with Self-Adaptive Threshold Strategy,” 2025 IEEE 6th International Seminar on Artificial Intelligence, Networking and Information Technology (AINIT), pp.1743–1748, 2025.

[11] K. Zhou, Y. Yang, Y. Qiao, and T. Xiang, “Domain generalization with mixstyle,” Proc. ICLR, pp.1–15, 2021.

[12] Y. Xiao, H. Yin, J. Bai, and R.K. Das, “FMSG-JLESS submission for DCASE 2024 task4 on sound event detection with heterogeneous training dataset and potentially missing labels,” arXiv:2407.00291, 2024.

[13] N. Turpault, R. Serizel, A.P. Shah, and J. Salamon, “Sound event detection in domestic environments with weakly labeled data and soundscape synthesis,” Workshop on Detection and Classification of Acoustic Scenes and Events, pp.1–5, 2019.

[14] R. Serizel, N. Turpault, A. Shah, and J. Salamon, “Sound event detection in synthetic domestic environments,” Proc. ICASSP, pp.86–90, 2020.

[15] I. Martín-Morató and A. Mesaros, “Strong labeling of sound events using crowdsourced weak labels and annotator competence estimation,” IEEE/ACM transactions on audio, speech, and language processing, vol.31, pp.902–914, 2023.

[16] Ç. Bilen, G. Ferroni, F. Tuveri, J. Azcarreta, and S. Krstulović, “A framework for the robust evaluation of sound event detection,” Proc. ICASSP, pp.61–65, 2020.

[17] D.P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” Proc. ICLR, pp.1–15, 2015.

[18] S. Chen, Y. Wu, C. Wang, S. Liu, D. Tompkins, Z. Chen, and F. Wei, “BEATs: Audio pre-training with acoustic tokenizers,” arXiv:2212.09058, 2022.

[19] H. Zhang, M. Cisse, Y.N. Dauphin, and D. Lopez-Paz, “mixup: Beyond empirical risk minimization,” Proc. ICLR, pp.1–13, 2018.

[20] B. Kim, S. Yang, J. Kim, H. Park, J. Lee, and S. Chang, “Domain generalization with relaxed instance frequency-wise normalization for multi-device acoustic scene classification,” arXiv:2206.12513, 2022.