一般社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
IEICE Technical Report

実環境を見据えた音による行動認識モデルの精度向上に関する一検討

竹本　志恩†　　川原　亮一†

† 東洋大学情報連携学部 〒115-8650 東京都北区赤羽台 1-7-11
E-mail: †{s1f102201278,ryoichi.kawahara}@iniad.org

あらまし　近年，少子高齢化による介護人材の不足が懸念される．その解決策として，行動認識による自立的な生活の支援がある．この行動認識はセンサによって実現される．主要なセンサはカメラやウェアラブルだが，それらを補完するため，マイクロフォンによる行動認識を検討する．特にプライバシーに配慮した高齢者見守りに向け，音響イベント検出の実環境適用を目指す．具体的には，モデルパラメータを増大させずに精度を向上させるため，信頼度を用いた半教師あり学習とドメイン汎化手法のアーキテクチャを改良し，統合した．本研究では先行実装などとの比較評価実験を通じて，提案手法の有効性を分析した．

キーワード　自立生活支援，行動認識，音響イベント検出

A Study on Improving Accuracy of Audio-Based Activity Recognition Models for Real-World Environments

Shion TAKEMOTO† and Ryoichi KAWAHARA†

† Faculty of Information Networking for Innovation and Design, Toyo University
1-7-11 Akabanedai, Kita-ku, Tokyo, 115-8650 Japan
E-mail: †{s1f102201278,ryoichi.kawahara}@iniad.org

Abstract　In recent years, there have been growing concerns regarding the shortage of nursing care personnel due to the declining birthrate and aging population. As a potential solution, supporting independent living through activity recognition has gained attention. While this is typically achieved using sensors—primarily cameras and wearables—we explore activity recognition via microphones to compensate for these existing technologies. Focusing on privacy-conscious elderly monitoring, we aim to apply Sound Event Detection (SED) to real-world environments. Specifically, to improve accuracy without increasing the number of model parameters, we refined and integrated architectures for semi-supervised learning using confidence scores and domain generalization. In this paper, we analyze the effectiveness of the proposed approach through comparative experiments with prior implementations.

Key words　Ambient Assisted Living, Human Activity Recognition, Sound Event Detection

1. はじめに

少子高齢化が急速に進行する日本において，介護資源の不足は深刻な社会問題であり，情報通信技術を活用して高齢者の自立生活を支援する Ambient Assisted Living (AAL) の重要性が高まっている．

AAL の要素技術である行動認識において，主流の一つであるウェアラブルセンサは，認知機能が低下した高齢者にとって装着忘れや充電管理の負担が大きく，常時監視による心理的・身体的ストレスも課題となる可能性がある．また，カメラによる監視は情報量が豊富である反面，プライバシーへの抵抗感が強く，浴室や洗面所といった事故リスクの高い場所への設置が困難であるほか，死角や暗所での認識精度低下も想定される．

これに対し本研究では，プライバシー受容性が高く，死角の影響を受けにくいマイクロフォン (マイク) を用いた音響イベント検出（Sound Event Detection; SED）に着目する．環境音を用いた SED は，流水音や転倒音といった特定の音響イベントを捉えることで，視覚情報を伴わずに危険な状況や生活文脈を把握できる可能性がある．しかし，実環境での運用には，生活雑音や部屋の残響特性といった環境要因による精度低下の克服が不可欠である．

また，近年の Detection and Classification of Acoustic Scenes and Events（DCASE）チャレンジ [1] 等における高精度モデルは大規模化する傾向にあるが，家庭内への実装を考慮すれば，計算

This article is a technical report without peer review, and its polished and/or extended version may be published elsewhere.
Copyright ©20xx by IEICE

リソースを抑えた軽量なモデルでの精度向上が求められる．

そこで本研究では，実環境での堅牢な行動認識を目指し，モデルパラメータを増大させずに SED の精度を向上させる手法を検討する．具体的には，信頼度を用いた半教師あり学習（Confident Mean Teacher; CMT）とドメイン汎化を目的とした MixStyle を改良し，統合した．

2. 関 連 研 究

2.1 行 動 認 識

日本における少子高齢化の進行に伴い，医療・介護資源の不足は喫緊の課題である．この解決策の一つとして，情報通信技術を活用して高齢者や障がい者の生活支援を行う AAL が挙げられる．AAL は在宅での自立生活を促進することで，医療や介護で発生する労働時間や社会保障費などの社会的コストを抑制すると同時に，被介護者の生活の質（Quality of Life; QoL）向上に寄与することを目指すものである [2]．

AAL の要素技術である行動認識は，センサを用いて居住者の行動を認識し，異常行動の検知や健康状態の把握を行う．従来の研究では，主にウェアラブルセンサ，カメラ，あるいはその他の環境設置型センサが用いられてきた．

ウェアラブルセンサは，対象者の状態を常時取得でき，転倒などの異常を即時に検知できる．しかし，高齢者の認知機能低下に伴う装着忘れや充電等の管理不備のリスクが伴う．加えて，常時機器を身につけることによる身体的な不快感や拘束感のみならず，被監視による心理的圧迫感が課題となることも考えられる [3]．

一方，カメラは情報量が豊富で具体的な行動認識が容易な上，身体への装着も不要である．しかし，マイクと比較して導入コストが高くなりがちであり，プライバシーの観点から被介護者の心理的抵抗感が強い場合もある．また，撮影範囲の死角や暗所における認識精度の低下も課題である [3], [4]．

その他の非接触な手法として，家具や床に設置する圧力センサや，無線通信波の変動を利用して行動を検知する環境センサなどを利用する方法がある [3]．これらは身体的負担がない点で優れるが，本研究ではこれらに加え，聴覚情報が持つ「環境音」や「発話」などの多面的な情報に着目する．

マイクは設置が容易でありながら，死角の影響を受けにくく，かつカメラよりもプライバシー受容性が高い．特に，カメラの設置が倫理的に難しい浴室や洗面所においては，その有用性は高いと考えられる [5]．例えば，ヒートショックによる転倒や溺水が発生した際，流水音の継続や転倒時の衝撃音といった特定の音響イベントを捉えることで，視覚的なプライバシーを侵害することなく異常を検知できる可能性がある．

しかし，実環境におけるマイクの運用には課題も残る．換気扇の稼働音や生活雑音などの環境ノイズ，あるいは部屋の形状に起因する残響特性の違いが，認識精度を低下させる要因となるためである [6]．

本研究はマイクを含む複数のセンサを統合し，多様な文脈を考慮した柔軟な行動認識システムの構築を目的に，その初期検討として，実環境におけるノイズなどの環境要因に対し，マイクによる行動認識精度を向上させる手法を検討する．

2.2 音響イベント検出

他方， 音響信号から事象の種類と発生時刻を特定する音響イベント検出（SED）の研究が活発化している．SED は， 音響イベントのクラス識別および時間区間検出を同時に行う技術であり， 本研究では音による行動認識の手段としてこれを位置付ける．本タスクではデータについて，10 秒間の音声を「クリップ」，そのより細かな単位を「フレーム」と定義する．これらはデータのラベルと対応する．「弱ラベル」はイベントの有無のみを示し，「強ラベル」はイベントの開始・終了時刻を含む．これら二種類のデータを入力として受け取り，音から何が起きたか (イベント種別) とそれらの開始・終了時刻を予測する．これら予測は，ラベルと関連して弱予測，強予測と呼ぶ．

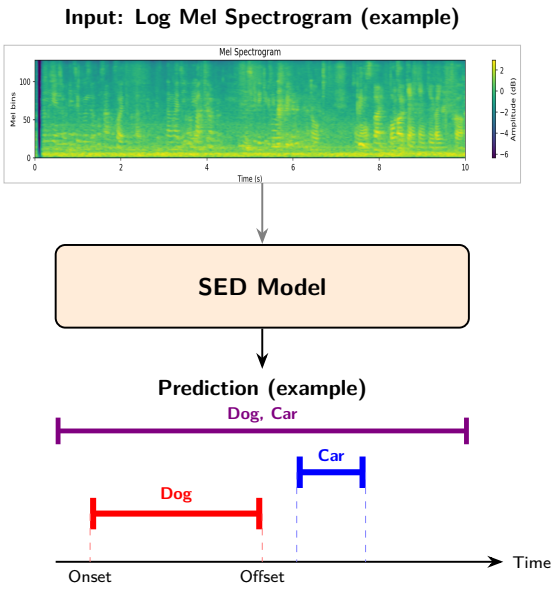


図 1 10 秒の音声入力を対象とした予測の概略．全体におけるイベントの有無を判定する弱予測に対し，強予測ではイベントの区間（Onset/Offset）も算出する．注: 入力のスペクトログラムと予測結果はあくまで構造を説明するためのイメージであり，実際の対応はない．

2.3 先 行 研 究

家庭内環境向け SED のコンペディションとして， DCASE チャレンジが知られている．DCASE 2024 Task 4 (DCASE 2024) は， 大規模な未ラベルデータを用いた複数の事前学習済みモデルの活用が精度向上に寄与し， 上位成績を収めた [7]．しかし， これらの手法はモデルの大規模化につながる可能性がある．実環境への実装を想定した場合， モデルのパラメータ数増加は望ましくない．本研究では， モデルサイズを維持しつつ精度を向上させることを目的に，半教師あり学習とドメイン汎化手法を改良及び統合する．

提案では，DCASE 2024 の評価基準モデルを先行実装(注1)と

(注1)：https://github.com/DCASE-REPO/DESED_task/tree/master/recipes/

する．なお，本研究は基本的に先行実装の設定に準拠する [1]．

先行実装は半教師あり学習手法として Mean Teacher (MT) を用いる．図 2 に MT の概略を示す．

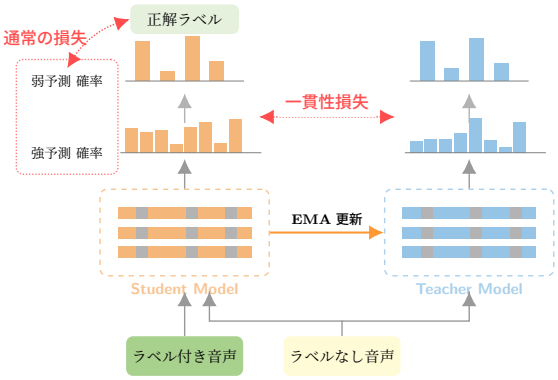


図 2　MT の更新の概略．DESED に対して適用する．Model 内の灰色部は，モデルの一部に DropOut が適用され，ノイズ (摂動) として働くことを表す．

これは通常のモデルを「生徒」，生徒モデルの重みパラメータの移動指数平均 (Exponential Moving Average; EMA) を「教師」と定義し，入力にノイズが加わろうと教師と生徒の予測は同様という仮定の下，両予測の差を一貫性損失として扱う．この損失は平均二乗誤差で求められる．MT では，教師がラベルなしデータに対して行う予測を擬似的な目標値とし，生徒予測との一貫性を高めることで，ラベルなしデータを活用する [8]．

MT に対して CMT は，教師予測に閾値を設け，信頼できる予測のみ学習に用いることで精度向上を図る [9]．CMT は確率値が 0.5 より大きい予測のみ用いるが，閾値未満の確率値を持つ予測は損失に寄与せず，「イベントがない」ことの学習が難しい．当環境で検証したところ，CMT は MT に比べてイベントの分類予測精度を向上したが，イベントの開始や終了時刻の予測精度（時間的な精度）は低下した．なお，CMT 及びその検証を行った論文ではイベント分類及び時間境界の精度の向上が報告されていた [10]．

本研究での提案として，確率値 0.7 以上の予測を正例，0.3 以下の予測を負例とし，両方を学習する．CMT に比べ，あまり自信のない確率値 0.5 付近の予測を使わず，より安定した精度が得られると共に，フレーム単位での「イベントがない」ことを学習することで，時間的精度の向上が期待される．

次に，ドメイン汎化について述べる．ここでドメインとは，同一のクラスラベルであっても，データが観測された環境や条件によって生じる特徴分布の違いを指す．例えば，画像認識では実写とイラストが異なるドメインとして扱われる．同様に，録音環境や背景雑音の違いにより，種類の同じ音響イベントでも周波数などの特徴が異なる．モデルがこうした環境依存の情報に過剰適合することを防ぎ，未知の環境でもロバストな推論を可能にすることがドメイン汎化の目的である．

MixStyle [11] はドメイン汎化に有効なデータ拡張手法の一つである．先行研究 [12] において周波数領域の注意機構との統合が示唆されているが，その具体的なアーキテクチャは詳述されていない．そこで本研究では，より軽量な畳み込みニューラルネットワーク (Convolutional Neural Network; CNN) での統合を提案する．

3. 先 行 実 装

3.1 データセット

評価用データセットとして Domestic Environment Sound Event Detection Dataset (DESED)(注2) の 10 クラス [13], [14]，及び MAESTRO Real(注3) の 11 クラス [15] の計 21 クラスを使用する．クラスの一覧は 6. 1. 1 節の表 3 に示す．

2. 2 節で述べたように，データのラベルには種類がある．10 秒の音声に対して，弱ラベルはイベント種別のみを示し，強ラベルはそれらの開始・終了時刻も示す．また，ラベルのないデータもある．

データセットに含まれる音声について，DESED は家庭内の音響イベント検出に向けて，実環境で録音した家庭内の生活音と，そのような環境を再現するために合成された音が含まれる．音声データは 10 秒間のモノラルオーディオで，サンプリングレート 16kHz または 44.1kHz となっている．MAESTRO Real は実環境の 3 – 5 分の音が含まれる．ラベルは 0 か 1 ではなく，0.8 などの連続値 (ソフトラベル) で，強ラベルが付与されている．

利用段階	データ種別	数 [clips]
訓練	強ラベル，実録音	1613
訓練	弱ラベル，実録音	1188
訓練	強ラベル，合成音	10000
訓練	ラベルなし，実録音	12027
検証	弱ラベル，実録音	129
検証	強ラベル，合成音	2500
評価	強ラベル，実録音	958

表 1　DESED のデータ数

DESED のデータは学習の利用段階と作成法，ラベルで分類される．利用段階には訓練，検証，評価がある．データは実環境の録音か，あるいは合成で作成される．なお，本研究では一部データが取得できていない．使用したデータ数を表 1 に示す．

MAESTRO Real は 6426 クリップが含まれており，訓練用のデータを訓練と検証で 9:1 に分割し，評価には評価用のデータを用いた．

3.2 評 価 指 標

本研究では DCASE2024 に基づき，データセットに応じて異なる評価指標を採用する．DESED では Polyphonic Sound Detection Score（PSDS）[16] のシナリオ 1 及び 2 を用い，MAESTRO Real では mpAUC（Macro-averaged Partial AUC．なお, AUC (Area

dcase2024_task4_baseline

（注2）：https://github.com/turpaultn/DESED

（注3）：https://researchportal.tuni.fi/en/datasets/maestro-real-multi-annotator-estimated-strong-labels/

Under the Curve) は ROC (Receiver Operating Characteristic) 曲線下部の面積）を主要な指標とする．

PSDS は，混同行列に基づく ROC 曲線を拡張した PSD-ROC 曲線を用いて算出される．通常の ROC 曲線は，縦軸に真陽性率（TPR），横軸に偽陽性率（FPR）をとるが，PSD-ROC 曲線では横軸に単位時間あたりの誤検知数（Effective False Positive Rate）を採用する点が異なる．

PSDS には目的に応じたシナリオが存在する．シナリオ 1（PSDS1）は時間的な正確さを重視し，イベントの検知区間が正解と厳密に一致することを求める一方，クラス分類の誤りには比較的寛容である．対照的に，シナリオ 2（PSDS2）はイベントのクラス分類性能を重視し，時間的なズレに対する許容範囲が広く設定されている．

本研究では，時間精度の向上とイベント分類の最適化を段階的に分離することを想定しており，現段階では正確なクラス分類を優先課題としている．したがって，PSDS2 を最重要指標と位置付けるが，モデルの総合的な挙動を把握するため PSDS1 も併せて評価する．

一方，MAESTRO Real の評価に用いる mpAUC は，ROC 曲線の全領域ではなく，誤検知率が低い領域（低 FPR 領域）に限定して AUC を算出する指標である．これは，実用上許容できない高い誤検知率の領域を評価から除外することで，モデルの信頼性をより厳密に評価するためである．

3.3 先行実装モデルの流れ

先行実装モデルの処理は学習と検証，評価の三段階に区分される．データの前処理の後，学習を 150 エポック行う．モデルは入力に対し，ラベルごとの予測（強/弱 予測）を出力する．予測と正解ラベルを用いて教師あり及び半教師あり学習の損失を計算し，Adam [17] で生徒モデルを，指数移動平均で教師モデルを更新する．

検証は 10 エポックごとに行う．学習したモデルで検証用データを入力に推論し，精度を測る．過去の検証より精度が向上した場合，評価及び推論用に重みパラメータを保持する．評価は評価用データで検証と同様の作業が行われる．

3.4 モデル構成

先行実装は図 3 のように，時間周波数領域の局所的な特徴を抽出する CNN と，時系列情報を学習しイベントの時間的変化をモデル化する再帰型ニューラルネットワーク（Recurrent Neural Network; RNN）を組み合わせた，CRNN（Convolutional Recurrent Neural Network）アーキテクチャである．特徴抽出器として事前学習された BEATs（Bidirectional Encoder representation from Audio Transformers）[18] を用いて，学習コストを抑制しながらタスクに有効な特徴表現を獲得する．BEATs への入力は CNN と次元数が異なるが，出力は時間解像度を補間することで CNN と統合される．

なお，特徴量は対数メルスペクトログラムを用い，その次元はバッチサイズ B，チャネル数 C，時間 (フレーム数) T，周波数 F である．また，前処理では汎化性能向上のため，二つのデータを一定の比率で混合するデータ拡張手法の Mixup を行う [19].

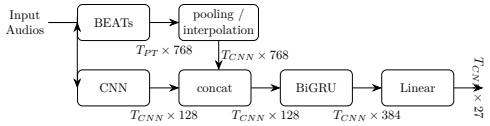


図 3　各段階の次元数は特徴量の時間長 (T，フレーム数) と周波数を表す．BEATs の出力を調整して CNN の出力と統合した後，RNN に入力し，最終的に予測を得る．なお，PT は事前学習済みモデルを表す．

3.4.1 CNN

CNN は図 4 のように, 7 つの畳み込みブロックで構成される．各ブロックでは Conv2D，Batch Normalization，ReLU，Dropout，及び MaxPool2D を順に積層する．

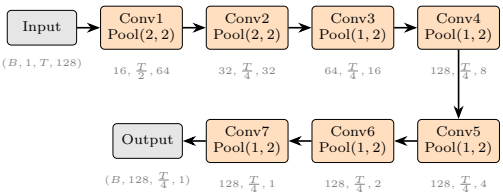


図 4　CNN の概略．各ブロック下の数値は特徴量の次元数を表す．

3.4.2 RNN

RNN には双方向 Gated Recurrent Unit（Bidirectional GRU; BiGRU）を使用し，順方向と逆方向に特徴を処理することで，イベントの時間的な変化を学習する．

3.5 出　　力

先行実装の出力段は RNN の出力（Batch × Time × 384，384 は周波数の次元数）を強/弱予測に変換する．出力は全結合層と Sigmoid 関数で強予測に変換され，それらを Attention 機構で時間方向に集約することで弱予測を得る．

4. 提 案 手 法

4.1 CMT [9]

CMT は MT の教師予測に対し，クリップ及びフレーム単位で閾値を適用する．まず，弱予測の結果に基づき，閾値未満の予測を同区間の強予測を含め学習対象から除外する．次に，閾値を上回る予測に対しては，イベント種別に応じた窓幅のメディアンフィルタを適用し，平滑化と外れ値の除去を行う．損失計算においては，二値化された信頼度マスクを重みとして，教師・生徒モデル間の二値交差エントロピー（Binary Cross Entropy; BCE）誤差を最小化する．

本実験環境において，CMT はイベント分類を重視する指標である PSDS2 を向上させた一方，時間境界の制度 (時間分解能) を重視する PSDS1 を低下させた．これは，低確信度の予測を損失計算から一律に除外することで，「イベントが存在しない」という負例の情報が学習されず，結果として時間境界の推定精度が損なわれたためと考えられる．

そこで本研究では，負例を明示的に学習に組み込み，PSDS2 の改善を維持しつつ，PSDS1 の向上を図る．具体的には，確率 0.7 以上を「信頼できる正例」，0.3 以下を「信頼できる負例」とし，不確実な中間領域の予測のみを学習から除外する．さらに，正負例のサンプル不均衡による精度低下を回避するため，サンプル数の比率に基づく損失の正規化を行う．

4.2 MixStyle

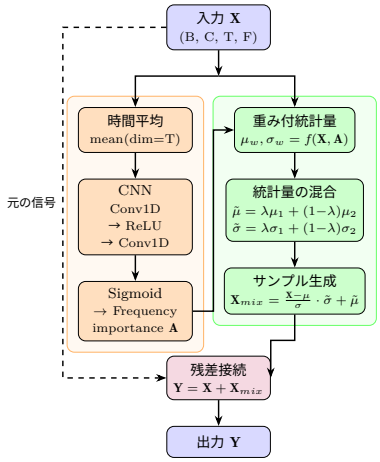


図 5　オレンジの領域が CNN，緑が MixStyle，そして赤が残差接続で，それぞれ本文の 1 から 3 に対応する．

MixStyle は，画像認識におけるドメイン汎化のために提案されたデータ拡張手法である．画像分野では空間情報に着目し，チャネルごとの平均と標準偏差をドメイン固有のスタイル統計量として抽出し，他データと混合する．一方で，音響信号は時間と周波数の次元を持ち，ドメイン情報は主に周波数領域に局在することが示唆されている [20]．この特性に基づき，Xiao ら [12] は時間方向の統計量を計算し，周波数軸に沿って混合する手法を提案した．これにより，元のデータに含まれる意味的な情報を保持しつつ，多様なドメインスタイルを生成し，特定ドメインへの過剰な適合を防ぐ．

しかし先行研究 [12] では，MixStyle と周波数方向の注意機構が結合されているものの，その統合プロセスや相互作用は詳らかにされていない．本研究では，周波数領域におけるドメイン汎化をより軽量に実現するため，MixStyle と CNN を統合する．本手法は以下の 3 段階で構成され，重要な信号情報を損なうことなく効果的なドメイン適応を実現する．

（1） CNN による重要周波数帯域の特定
（2） 重要度を考慮した重み付き統計量の混合
（3） 残差接続による原信号のドメイン情報の保持

具体的なアーキテクチャを図 5 に示す．MixStyle の適用は [12] に倣い，CNN への入力直前，及び第 1・第 2 畳み込み層直後の特徴量を対象とした．ハイパーパラメータは [11] を参照し，適用確率を $p = 0.5$，ベータ分布のパラメータを $\alpha = 0.1$ に設定した．混合対象であるスタイル統計量は，ミニバッチ内からランダムに選択される．本実験では，ドメイン汎化の対象として合成音（DESED）と実録音（MAESTRO Real）を扱うが，MixStyle はランダムな選択であっても十分な正則化効果が得られることが報告されている．したがって，計算コストと実装の簡便性を優先し，異なるスタイルを持つデータを選択して混合するのではなく，バッチ内ランダム選択による混合を行った．

提案手法の詳細を以下に述べる．入力特徴量を $X \in \mathbb{R}^{B\times C\times T\times F}$ とする．まず，時間方向の平均を算出することで時間情報を集約し，周波数特徴記述子 $Z \in \mathbb{R}^{B\times C\times F}$ を得る．

$$Z_{b,c,f} = \frac{1}{T}\sum_{t=1}^{T} X_{b,c,t,f}$$

次に，Z に対して CNN を適用し，周波数ごとの重要度マップ $A \in \mathbb{R}^{B\times C\times 1\times F}$ を生成する．ネットワーク構成には，カーネルサイズ 3 の 1 次元畳み込み層，ReLU 関数 δ，及びカーネルサイズ 1 の 1 次元畳み込み層からなるボトルネック構造を採用した．最終層には Sigmoid 関数 σ を適用し，出力を $(0, 1)$ の範囲に正規化する．

$$A = \sigma(W_2 \cdot \delta(W_1 \cdot Z))$$

ここで，W_1, W_2 は畳み込み層の重みを表す．なお，学習初期の勾配消失を抑制し，統計量の混合を促進するため，最終層のバイアスは 1.0 で初期化した．

推定された重要度 A に基づき，周波数ごとの重み付き平均 μ 及び重み付き標準偏差 σ を算出する．これらを用いて正規化及び異種ドメイン（ミニバッチ内の他サンプル）との混合を行い，新たな特徴量 X_{mix} を生成する．最後に，元の信号情報の損失を防ぎつつドメイン不変性を獲得するため，下式に示す残差構造を導入する．

$$Y = X + \mathrm{MixStyle}(X, A)$$

この残差構造により，モデルは主要な音響イベント情報を保持したまま，MixStyle によるドメイン変動に対する頑健性を効率的に学習できる．

5. 実　　験

先行実装及び先行研究に対する精度向上及び各要素の有効性を示すため，本研究では 3 つの実験を行う．

(i) まず，先行実装（MT），先行研究（CMT），及び提案手法を対象とし，それぞれの識別性能を評価する．(ii) 次に，MixStyle を既存モデルに直接適用する場合と，軽量 CNN を介して統合する場合とで，精度を比較する．(iii) 最後に，構成要素の比較を行う．半教師あり学習の三手法に対し，MixStyle を併用して学習を行い，上記の結果と合わせて各モジュールの導入効果を検証する．

6. 結果と考察

6.1 CMT

MT-type	PSDS1	PSDS2	mpAUC
Mean Teacher(MT)	0.369	0.581	0.720
Confident Mean Teacher(CMT)	0.297	0.60	0.689
CMT_{neg}	0.369	0.543	0.661
CMT_{scale}	0.368	0.621	0.699

表 2　Mean Teacher 比較

表 2 に各手法の精度比較を示す．MT と比較して，CMT は PSDS2 が向上したが，PSDS1 及び mpAUC は低下した．本研究の提案手法について見ると，正負例を学習する CMT_{neg} は，CMT における PSDS1 の低下を改善したが，他の精度は悪化した．正負例を均衡化する CMT_{scale} は，MT と同等の PSDS1 を維持しつつ，CMT を上回る PSDS2 を示した．ただし，mpAUC は MT に及ばなかった．

CMT における PSDS1 の低下は，非イベント区間の情報（負例）の欠落で時間的な予測が不安定になったためと考えられる．CMT_{neg} では負例の導入によりこの問題を解決したが，正例に対する負例の割合が過多となり，逆にクラス分類（PSDS2 及び mpAUC）の予測が不安定化した．よって，負例の使用と正負例の量の調整が，PSDS1，2 の安定に有効である．

6.1.1 クラス別 CMT

PSD2（DESED）				mpAUC（MAESTRO）			
class	MT	CMT	CMT_s	class	MT	CMT	CMT_s
Alarm_bell	.868	.937	**.947**	Birds_singing	.971	.969	**.972**
Blender	.870	.885	**.920**	Brakes_squeak	.416	.398	**.463**
Cat	.881	**.929**	.911	**Car**	.825	**.866**	.817
Dishes	.501	**.641**	.602	Children voices	**.916**	.868	.881
Dog	.848	**.893**	.883	Cutlery/dishes	.595	.584	**.617**
Elec_shaver	.965	**.989**	.984	**Footsteps**	.681	.696	**.710**
Frying	.958	.948	**.970**	Large_vehicle	.653	.659	**.681**
Running_water	.887	.902	**.912**	**Metro approach**	**.833**	.807	.782
Speech	.775	.853	**.862**	Metro leaving	**.768**	.756	.740
Vacuum_clean	.901	.912	**.948**	People talking	**.665**	.662	.662
				Wind_blowing	.599	.324	**.744**

表 3　クラス別精度比較（CMT_s は CMT_{scale} の略）

CMT におけるクラスごとの精度を表 3 に示す．本研究の将来的な目標である異常検知において，異常発生の重要な文脈となる「流水（Running water）」と「足音（Footsteps）」に着目する．MT と比較して，提案手法である CMT_{scale} は，流水の PSDS2 において 0.88 から 0.91 へ，足音の mpAUC において 0.68 から 0.71 へと，それぞれ精度を向上達成した．

また，表 3 では，提案手法と MT 及び CMT を比較して 5% 以上の変化があるクラスについて，向上は青，低下は赤で強調した．向上クラスは音が長く持続するが，低下クラスでは瞬間的な音が続く．このことから，提案手法は長期的な音が捉えられる代わりに，瞬間的な音を取りこぼすと考えられる．

6.2 MixStyle

表 4 より，CNN での重み付けによって PSDS2 と mpAUC が向上した．なお，半教師あり学習手法として MT を用いた．これはドメイン汎化がより促されたか，モデルの入力が変化し，一貫性の制約が強まったためと考えられる．ただ，重みづけは実際には働いていない可能性がある．また，従来の MixStyle は混合した特徴量のみを用いるが，提案は残差接続を行う．これが摂動として働き，一貫性の制約を強めた可能性もある．

CNN	PSDS1	PSDS2	mpAUC
-	0.375	0.581	0.709
✓	0.373	0.596	0.745

表 4　MixStyle+CNN

6.3 CMT+MixStyle

MT-type	MixStyle	PSDS1	PSDS2	mpAUC
先行実装 (MT)	-	0.369	0.581	0.720
先行実装	✓	0.382	0.607	0.704
先行研究 (CMT)	-	0.297	0.60	0.689
先行研究	✓	0.387	0.637	0.722
提案手法 (CMT_{scale})	-	0.368	0.621	0.699
提案手法	✓	0.393	0.632	0.727

表 5　CMT+MixStyle

表 5 に，各種 MT を MixStyle と併用した場合の結果を示す．MT と CMT は PSDS1，2 が向上した一方で，mpAUC は低下した．CMT_{scale} は MT に比べて精度が向上したが，CMT との差は僅かである．これは MixStyle の精度への影響が CMT より強いためだと考えられる．

MixStyle の適用については，DESED（合成音・実録音）のみならず，性質の異なる MAESTRO（実録音）を含む精度向上が期待されたが，MT では mpAUC が低下した．特に PSDS1，2 の向上は，MixStyle が特徴空間に摂動を与え，教師及び生徒モデル間の一貫性を強めたためと考えられる．

6.4 ま と め

一連の結果より，提案手法である CMT と MixStyle の改良を統合した場合，MT と比較して全ての指標を向上させたが，CMT との差はごく僅かだった．正例に加え負例を活用する CMT_{scale} の有効性は示されたように思うが，あくまで MT の範疇である．また，MixStyle と軽量 CNN による重み付けも，精度向上に一定の寄与をすることが確認された．

7. む す び

本研究では，DCASE2024 Task 4 の評価基準モデルを基盤に，半教師あり学習とドメイン汎化手法の改善と統合によって，音響イベント検出の精度向上を図った．結果として，負例を活用した CMT は，従来の MT や単純な CMT と比較して PSDS1，PSDS2 を向上させた．また，周波数ごとの重要度に基づく MixStyle の有効性を再確認し，軽量な CNN でもドメイン汎化の効果が得られることを示した．

今後の課題として，CMT と MixStyle を併用した際に観測された，ベストモデル到達エポック数の減少（早期収束または不

安定性）に関する詳細な解析や，他の半教師あり学習手法との性能比較，モデルの軽量化，時間推定の分離が挙げられる．

文　献

[1] S. Cornell, J. Ebbers, C. Douwes, I. Martín-Morató, M. Harju, A. Mesaros, and R. Serizel, "Dcase 2024 task 4: Sound event detection with heterogeneous data and missing labels," arXiv:2406.08056, 2024.

[2] S. Blackman, C. Matlo, C. Bobrovitskiy, A. Waldoch, M.L. Fang, P. Jackson, A. Mihailidis, L. Nygård, A. Astell, and A. Sixsmith, "Ambient assisted living technologies for aging well: a scoping review," Journal of Intelligent Systems, vol.25, no.1, pp.55–69, 2016.

[3] B.M.V. Guerra, E. Torti, E. Marenzi, M. Schmid, S. Ramat, F. Leporati, and G. Danese, "Ambient assisted living for frail people through human activity recognition: state-of-the-art, challenges and future directions," Frontiers in neuroscience, vol.17, p.1256682, 2023.

[4] D. Bouchabou, S.M. Nguyen, C. Lohr, B. LeDuc, and I. Kanellos, "A survey of human activity recognition in smart homes based on iot sensors algorithms: Taxonomies, challenges, and opportunities with deep learning," Sensors, vol.21, no.18, p.6037, 2021.

[5] S.H. Hyun, "Sound-event detection of water-usage activities using transfer learning," Sensors, vol.24, no.1, p.22, 2023.

[6] A. Mesaros, T. Heittola, T. Virtanen, and M.D. Plumbley, "Sound event detection: A tutorial," IEEE Signal Processing Magazine, vol.38, no.5, pp.67–83, 2021.

[7] F. Schmid, P. Primus, T. Morocutti, J. Greif, and G. Widmer, "Improving audio spectrogram transformers for sound event detection through multi-stage training," arXiv:2408.00791, 2024.

[8] A. Tarvainen and H. Valpola, "Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results," Advances in Neural Information Processing Systems, vol.30, pp.1195–1204, 2017.

[9] S. Xiao, X. Zhang, and P. Zhang, "Multi-dimensional frequency dynamic convolution with confident mean teacher for sound event detection," Proc. ICASSP, pp.1–5, 2023.

[10] Z. Niu, Q. Wu, and Y. Hu, "Sat-sed: Semi-supervised sound event detection by pseudo-labeling with self-adaptive threshold strategy," 2025 IEEE 6th International Seminar on Artificial Intelligence, Networking and Information Technology (AINIT), pp.1743–1748, 2025.

[11] K. Zhou, Y. Yang, Y. Qiao, and T. Xiang, "Domain generalization with mixstyle," Proc. ICLR, pp.1–15, 2021.

[12] Y. Xiao, H. Yin, J. Bai, and R.K. Das, "Fmsg-jless submission for dcase 2024 task4 on sound event detection with heterogeneous training dataset and potentially missing labels," arXiv:2407.00291, 2024.

[13] N. Turpault, R. Serizel, A.P. Shah, and J. Salamon, "Sound event detection in domestic environments with weakly labeled data and soundscape synthesis," Workshop on Detection and Classification of Acoustic Scenes and Events, pp.1–5, 2019.

[14] R. Serizel, N. Turpault, A. Shah, and J. Salamon, "Sound event detection in synthetic domestic environments," Proc. ICASSP, pp.86–90, 2020.

[15] I. Martín-Morató and A. Mesaros, "Strong labeling of sound events using crowdsourced weak labels and annotator competence estimation," IEEE/ACM transactions on audio, speech, and language processing, vol.31, pp.902–914, 2023.

[16] Ç. Bilen, G. Ferroni, F. Tuveri, J. Azcarreta, and S. Krstulović, "A framework for the robust evaluation of sound event detection," Proc. ICASSP, pp.61–65, 2020.

[17] D.P. Kingma and J. Ba, "Adam: A method for stochastic optimization," Proc. ICLR, pp.1–15, 2015.

[18] S. Chen, Y. Wu, C. Wang, S. Liu, D. Tompkins, Z. Chen, and F. Wei, "Beats: Audio pre-training with acoustic tokenizers," arXiv:2212.09058, 2022.

[19] H. Zhang, M. Cisse, Y.N. Dauphin, and D. Lopez-Paz, "mixup: Beyond empirical risk minimization," Proc. ICLR, pp.1–13, 2018.

[20] B. Kim, S. Yang, J. Kim, H. Park, J. Lee, and S. Chang, "Domain generalization with relaxed instance frequency-wise normalization for multi-device acoustic scene classification," arXiv:2206.12513, 2022.